V-CREDIT · CASE FINAL ROCKET LAB

Documentação técnica

Arquitetura medalhão, pipeline e painel de indicadores

Case RJ – Grupo 2

Anna Cristina · Gabriel Guimarães · Juan Perri · Milton Salgado · Richard · Yuri

22 de outubro de 2026

VISAGIO

Sumário

1 Visão geral técnica **3**
- 1.1 Onde está cada entregável técnico 3
- 1.2 Estrutura do repositório 4

2 Arquitetura medalhão **5**
- 2.1 Bronze — Landing_To_Bronze.ipynb 5
- 2.2 Silver — Bronze_To_Silver.ipynb 5
- 2.3 Gold — Silver_To_Gold.ipynb 6
- 2.4 Gold → CSV — Gold_To_CSV.ipynb 6
- 2.5 Rastreabilidade, qualidade e integridade — resumo 6
- 2.6 Colunas de linhagem 7
- 2.7 Fonte da verdade dos tempos 7
- 2.8 Escalabilidade 8
- 2.9 Decisões do grupo 8

3 Notebooks, Job e idempotência **12**
- 3.1 Notebooks 12
- 3.2 Ordem e dependências 12
- 3.3 Job de atualização (Databricks Workflows) 12
- 3.4 Idempotência: evidência 13

4 Painel de indicadores (Power BI) **17**
- 4.1 O que é e onde está 17
- 4.2 Fonte de dados: as 14 tabelas analíticas 17
- 4.3 As 7 páginas 18
- 4.4 Como abrir 19
- 4.5 Conferência dos cartões (período completo) 19
- 4.6 Limitações 20

5 Ambiente e operação no Databricks **21**
- 5.1 Estrutura real 21
- 5.2 Como os dados são lidos 21
- 5.3 Passo a passo (montar do zero) 21
- 5.4 Conferência dos números 22
- 5.5 Problemas comuns 22
- 5.6 Regras de segurança e sincronia 23
- 5.7 Checklist 23

6 Histórico de revisões da silver e da gold **24**
- 6.1 Correções aplicadas após a revisão (20/10/2026) 24
- 6.2 Segunda rodada de correções (21/10/2026) — já commitadas na main 25
- 6.3 Terceira rodada (21/10/2026) — nome_atendente volta a aparecer 25
- 6.4 Quarta rodada (21/10/2026) — diagramas alinhados à terceira rodada 26
- 6.5 Quinta rodada (21/10/2026) — Silver_To_Gold.ipynb chegou, revisado 26
- 6.6 Sexta rodada (21/10/2026) — diagrama gold e PDF alinhados à decisão do hash 27

7 Convenções de Git **28**
- 7.1 Regra geral 28
- 7.2 Branches 28
- 7.3 Commits 28

7.4 Pull Requests 28

8 Anexo A — Capturas do painel 29

9 Anexo B — Evidências da idempotência 37

9.1 Cuidados 37

1 Visão geral técnica

Este documento reúne a solução técnica do case V-Credit (Visagio / Rocket Lab 2026): uma **arquitetura medalhão** em Databricks Free Edition, notebooks documentados, um **Job automático** com pipeline idempotente e um **painel de indicadores** em Power BI. Ele é a versão consolidada e revisada da documentação do repositório e acompanha o código de `medalhao/` e o projeto de `powerbi/`.



BASE ANALISADA
131.838
chamados únicos, jan/2025 a jul/2026

TABELAS GOLD
23
1 fato, 1 auditoria, 7 dimensões, 14 analíticas

JOB
2×/dia
00:00 e 12:00 (America/Sao_Paulo), 4 tarefas

IDEMPOTÊNCIA
22 de 22
tabelas exportadas idênticas entre duas rodadas

Segurança e privacidade. O enunciado e as bases do case são confidenciais. Nenhum CSV, `.zip` ou `.pbix` com dados vai para o Git, e a camada gold guarda apenas o `id_cliente_hash`: CPF, nome e e-mail de clientes não existem na gold nem na exportação.

1.1 Onde está cada entregável técnico

Entrega esperada (enunciado)	Onde está neste documento	No repositório
Arquitetura medalhão: ingestão, tratamento e consolidação, com rastreabilidade, qualidade e integridade	Capítulo 2	`docs/tecnico/arquitetura-medalhao.md` e `medalhao/`
Notebooks documentados em Databricks Free Edition	Capítulos 2 e 3	`medalhao/` (4 notebooks)
Jobs automáticos entre os notebooks; pipeline idempotente	Capítulo 3 e Anexo B	`docs/tecnico/notebooks-e-jobs.md` e `docs/tecnico/evidencias/`
Painel de indicadores consolidado	Capítulo 4 e Anexo A	`powerbi/painel-v-credit/` e `docs/tecnico/painel-indicadores.md`
Ambiente e operação no Databricks	Capítulo 5	`docs/databricks-estrutura.md`
Decisões e correções da silver e da gold	Capítulo 6	`docs/tecnico/historico-revisoes-silver-gold.md`

1.2 Estrutura do repositório

```
.
├── README.md
├── CLAUDE.md                       contexto e regras para o Claude Code
├── medalhao/                       código da arquitetura medalhão (= pasta medalhao/ do Databricks)
│   ├── README.md                   ordem de execução, tabelas lidas e gravadas
│   ├── Landing_To_Bronze.ipynb     8 CSVs → *_raw
│   ├── Bronze_To_Silver.ipynb      limpeza e junção → *_silver + base_silver
│   ├── Silver_To_Gold.ipynb        modelo em estrela + 14 tabelas analíticas → *_gold
│   ├── Gold_To_CSV.ipynb           exporta a gold para o Power BI (Volume)
│   └── modelagem/                  diagramas da silver e da gold; guia da gold (PDF)
├── powerbi/                        painel Power BI em formato PBIP (texto): relatório com 7 páginas e
modelo semântico; sem dados
│   └── painel-v-credit/            Painel_Atendimento_VCredit.pbip, .Report e .SemanticModel
├── resultados/                     números da análise, um arquivo por frente (01 a 07)
├── docs/
│   ├── README.md                   mapa: item do enunciado → arquivo
│   ├── tecnico/                    arquitetura, notebooks e jobs, painel, histórico de revisões
│   ├── analitico/                  confiabilidade, propostas, oportunidades, roteiro da apresentação
│   ├── convencoes-git.md           branches, commits (Conventional Commits) e Pull Requests
│   └── databricks-estrutura.md     pastas, permissões e troubleshooting no workspace
└── data/                           fora do git (só o README): raw/ (8 CSVs) e powerbi/ (pacote CSV
exportado pelo Job)
```

2 Arquitetura medalhão

Entregável técnico (Diretor de Tecnologia): camadas de ingestão, tratamento e consolidação, com rastreabilidade, qualidade e integridade. Código em `../../medalhao/`.

```
CSVs (Workspace)  →  Bronze (*_raw)  →  Silver (*_silver)  →  Gold (*_gold)  →  CSV / Power BI
 8 arquivos           8 tabelas          9 tabelas + base       7 dim + fato +       Volume
                      tudo string        tipadas, flags dq_*    qualidade + 14 OLAP  exportacao_powerbi
```

Ambiente: Databricks Free Edition (serverless), catálogo `dados_vcredit`, schema `default`.

2.1 Bronze — Landing_To_Bronze.ipynb

- **Fiel à origem**: as 8 tabelas entram como `string` (`inferSchema=false`), sem renomear nem corrigir nada.
- **Encoding por arquivo**: `clientes` e `Chamados_Hora` são `ISO-8859-1`; as demais `UTF-8`. Sem isso os acentos quebram.
- **Rastreabilidade**: toda tabela ganha `_source_file`, `_source_file_mod_ts` e `_ingestion_ts`.
- **Idempotência**: `overwrite` por tabela. Contagens: `chamados` 134.474, `chamados_hora` 131.838, `clientes` 47.705, `custos` 131.069, `pesquisa_satisfacao` 81.021, `base_atendentes` 25, `base_motivos` 14, `canais` 4.

2.2 Silver — Bronze_To_Silver.ipynb

Notebook único, uma seção por tabela, mais a seção 8 (consolidado). Toda anomalia vira flag `dq_*`; nenhuma linha é descartada em silêncio (a única remoção são duplicatas idênticas).

Tabela	Tratamento principal
`chamados_silver`	2.636 `id_chamado` duplicados removidos (134.474 → 131.838); `canal_chave` / `motivo_chave` normalizados (minúsculo, sem acento); `resolvido` booleano; `id_atendente` placeholder (0, 99, 999) ou vazio marcado em `dq_atendente_invalido`
`clientes_silver`	`id_cliente` (CPF) só como chave de junção e nunca exibido; idade fora de 18-110 vira inválida; `regiao` padronizada
`atendentes_silver`	nível extraído como 1 ou 2; datas de admissão/desligamento viram `date`
`motivos_silver`	`criticidade` em minúsculo; `categoria` vazia vira "Outro"
`canais_silver`, `canais_depara_silver`	nome oficial via `ALIASES`; de-para variação → `id_canal` (0 variações sem correspondência)
`custos_silver`	`custo` em formatos mistos limpo sem inflar o valor (ver abaixo); `decimal(12,2)`; 781 `id_custo` duplicados removidos
`pesquisa_satisfacao_silver`	nota válida só de 1 a 5 (`dq_nota_invalida`); `nota_ajustada` (6→5; 0 e -1→1) como premissa explícita
`chamados_hora_silver`	**fonte da verdade dos tempos**; ano de abertura corrigido em 198 chamados; virada de dia corrigida em 1

Tabela	Tratamento principal
`base_silver`	junção final, uma linha por `id_chamado`; `dq_cliente_sem_correspondencia` (~1,0% dos chamados)

Regras que mudam número (detalhes e impacto em `../analitico/confiabilidade-dos-dados.md`):

- **Tempos** vêm só dos timestamps de `chamados_hora`. O `tempo_atendimento` de `chamados` é truncado para durações ≥ 1.000 s e nunca é usado.
- **Custo**: com vírgula, ela é o decimal brasileiro (pontos de milhar saem antes); sem vírgula, o ponto já é decimal. Remover todo ponto, como no notebook exploratório inicial, inflava o total para ~R$ 42 mi (o correto é ~R$ 1,45 mi). Na `base_silver` e na gold só entram lançamentos > 0.

2.3 Gold — Silver_To_Gold.ipynb

Esquema em estrela (diagrama em `../../medalhao/modelagem/modelagem-gold.png`; guia célula a célula em PDF na mesma pasta):

- **Fato** `fato_atendimento_gold`: 1 linha por chamado (22 colunas), 131.838 linhas.
- **Auditoria** `qualidade_chamado_gold`: 1 para 1 com a fato (24 colunas), onde ficam as flags de qualidade.
- **7 dimensões**: `dim_calendario` (731), `dim_hora` (25), `dim_faixa_espera` (6), `dim_canal` (5), `dim_motivo` (15), `dim_atendente` (28), `dim_cliente` (47.705).
- **14 tabelas analíticas** prontas para BI: `visao_geral`, `kpi_mensal`, `comparativo_yoy`, `funil_atendimento`, `etapa_mensal`, `motivos_pareto`, `motivo_etapa`, `demanda_dia_hora`, `atendentes_desempenho`, `satisfacao_drivers`, `perfil_cliente`, `qualidade_dados`, `impacto_indicadores`, `simulacao_ganhos`.

Garantias de integridade:

- **Nenhum chamado se perde**: todos os joins da fato são `LEFT`; o que não casa vira membro desconhecido (chave `-1`, e `-1/-2/-3` em atendente), nunca linha descartada. O notebook confere `n_fato == n_chamados` e **interrompe** se houver chave órfã ou duplicada.
- **Funil**: `dim_canal.etapa_funil` mapeia URA/Chatbot → Autosserviço, Atendimento Inicial → Nível 1, Atendimento Especializado → Nível 2. A etapa Prevenção (site/app) não existe nos dados.
- **Catálogo**: o schema `dados_vcredit.default` tem 23 tabelas `_gold`, todas criadas por `Silver_To_Gold` (6 tabelas de teste anteriores à gold final foram removidas).

2.4 Gold → CSV — Gold_To_CSV.ipynb

Exporta o modelo de consumo (1 fato + 7 dimensões) e as 14 analíticas para o Volume `exportacao_powerbi`, porque o Free Edition não tem integração nativa com o Power BI (enunciado, p. 9-10). Detalhes em `painel-indicadores.md`.

2.5 Rastreabilidade, qualidade e integridade — resumo

Requisito	Como é atendido
Rastreabilidade	`_source_file` / `_ingestion_ts` na bronze; `_manifesto.csv/json` na exportação (id do pacote, versão Delta de cada tabela de origem, linhas, colunas, checksum)
Qualidade	Flags `dq_*` na silver; `qualidade_chamado_gold` e `qualidade_dados_gold` na gold; `impacto_indicadores_gold` mede quanto cada tratamento move cada KPI

Requisito	Como é atendido
Integridade	Dedup por chave na silver; checagem de órfãos, chaves únicas e contagem da fato na gold
Idempotência	`overwrite` / `CREATE OR REPLACE` em toda tabela; CSVs regravados por inteiro, em ordem fixa, com checksum independente da ordem
Segurança / privacidade	`id_cliente` (CPF) só como chave interna na silver e **nunca exibido**; na gold e na exportação existe apenas `id_cliente_hash`; nome, e-mail e CPF não existem na gold

2.6 Colunas de linhagem

Quatro colunas existem só para rastrear a execução e **mudam a cada rodada por definição**; todas ficam fora do checksum de idempotência (ver `notebooks-e-jobs.md`):

Coluna	Onde	O que guarda
`_source_file`, `_source_file_mod_ts`	Todas as tabelas `*_raw`	Arquivo de origem e a data de modificação dele (não mudam se o CSV não mudar)
`_ingestion_ts`	Todas as tabelas `*_raw`	Hora da ingestão
`_treatment_ts`	`canais_silver`	`current_timestamp()` do tratamento; **não** é levada para a gold
`versao_bronze`	`chamados_hora_silver`	Versão Delta de `chamados_hora_raw` usada no tratamento (sobe a cada ingestão)

2.7 Fonte da verdade dos tempos

O enunciado (consideração 6) pede que o grupo decida e documente qual fonte vale quando um campo calculado diverge do registro de horário.

Decisão: todos os tempos (TME, TMA e tempo total) vêm **somente dos timestamps de `chamados_hora`** (abertura, início e finalização), tratados na silver (`chamados_hora_silver`). O campo `tempo_atendimento` de `chamados` **nunca é usado em indicador**.

Por quê: o campo está truncado para durações a partir de 1.000 s, então subestima o TMA humano.

Conferido no Databricks em 22/10/2026 (~03h e ~03h30). `chamados_raw` tem 134.474 linhas e 131.838 `id_chamado` distintos; cruzando com `fato_atendimento_gold`, há 127.375 chamados com os dois valores:

Medida	Campo `chamados.tempo_atendimento`	Timestamps (`fato_atendimento_gold`)
Chamados com os dois valores	127.375	127.375
Média	216,6 s (3,6 min)	662,3 s (11,0 min)
Chamados com duração ≥ 1.000 s	—	27.987 (22,0%)
Média nos chamados com duração ≥ 1.000 s	1,6 s	2.030,1 s
Valor máximo	999 s	9.000 s
Chamados em que o campo é maior que os timestamps	0	—

O campo subestima o TMA em ~3,1 vezes (216,6 s contra 662,3 s) e chega a ~0 nos 22% de chamados que passam de 1.000 s (1,6 s contra 2.030,1 s em média).

Query de conferência no Databricks (rodada em 22/10/2026; as colunas conferem com a tabela acima):

```
WITH r AS (
  SELECT DISTINCT id_chamado, try_cast(tempo_atendimento AS DOUBLE) AS campo_s
  FROM dados_vcredit.default.chamados_raw
), j AS (
  SELECT r.campo_s, f.tempo_atendimento_seg AS ts_s
  FROM r JOIN dados_vcredit.default.fato_atendimento_gold f USING (id_chamado)
  WHERE r.campo_s IS NOT NULL AND f.tempo_atendimento_seg IS NOT NULL
)
SELECT COUNT(*) AS n,
       ROUND(AVG(campo_s), 1) AS media_campo_s,
       ROUND(AVG(ts_s), 1) AS media_timestamp_s,
       COUNT_IF(ts_s >= 1000) AS duracao_ge_1000s,
       ROUND(AVG(CASE WHEN ts_s >= 1000 THEN campo_s END), 1) AS media_campo_ge_1000s,
       ROUND(AVG(CASE WHEN ts_s >= 1000 THEN ts_s END), 1) AS media_timestamp_ge_1000s,
       MAX(campo_s) AS max_campo_s,
       MAX(ts_s) AS max_timestamp_s,
       COUNT_IF(campo_s > ts_s) AS campo_maior_que_timestamp
FROM j
```

2.8 Escalabilidade

Hoje todas as tabelas são regravadas por inteiro (`overwrite` / `CREATE OR REPLACE`) a cada 12 h, o que é adequado ao volume atual (~130 mil chamados, execução de 7 a 8 min no serverless). Para volumes maiores, o caminho é:

- **Carga incremental** na bronze e na silver (por exemplo, `MERGE` por `id_chamado` / `id_custo` e ingestão por arquivo novo), no lugar do `overwrite` completo.
- **Particionamento por data** na fato e nas tabelas de grande volume, e `OPTIMIZE` periódico das tabelas Delta.
- **Parâmetros de Job** (por exemplo, `anonimizar_atendente`) em vez de editar notebook.
- O desenho em camadas e a idempotência por chave seguem valendo: só muda como cada camada atualiza as tabelas.

2.9 Decisões do grupo

Decisão	Escolha	Motivo
Hash do `id_cliente`	`sha2` (SHA-256) puro, sem segredo/HMAC	O `id_cliente` do case é dado fictício, não CPF real; o risco de reversão por força bruta que justificaria o HMAC não se aplica. Em dado real, usar HMAC com segredo
`nome_atendente`	Não é dado restrito (a regra vale para CPF/nome/e-mail de **cliente**)	A exportação tem o parâmetro `anonimizar_atendente` (padrão `false`) para trocar o nome por "Atendente "
`status_atendente`	Mantido com esse nome em `chamados_silver`; só vira `status_id_atendente` na `base_silver`	Evita colisão com `atendentes_silver.status_atendente` (significado diferente: ativo/inativo no cadastro)

Decisão	Escolha	Motivo
Clientes sem cadastro (1.330 chamados, 1,0%)	Membro `SEM_CADASTRO` criado na exportação para o Power BI (`dim_cliente` do modelo de consumo)	Esses chamados não somem dos relatórios
Tipos em `dim_cliente_gold`	`data_cadastro` vira `date`, `dia_vencimento_fatura` vira `int`	A silver entrega string
Fonte da verdade dos tempos	Só os timestamps de `chamados_hora`; `chamados.tempo_atendimento` nunca entra em indicador	Campo truncado (seção "Fonte da verdade dos tempos")

Decisão do grupo: nomes dos atendentes mantidos no material do Comitê (base fictícia); `anonimizar_atendente` fica `false`. Ver também `../analitico/confiabilidade-dos-dados.md`.

Diagramas de modelagem

Os diagramas abaixo foram refeitos conforme o código atual dos notebooks (rodadas de revisão descritas no capítulo 6).

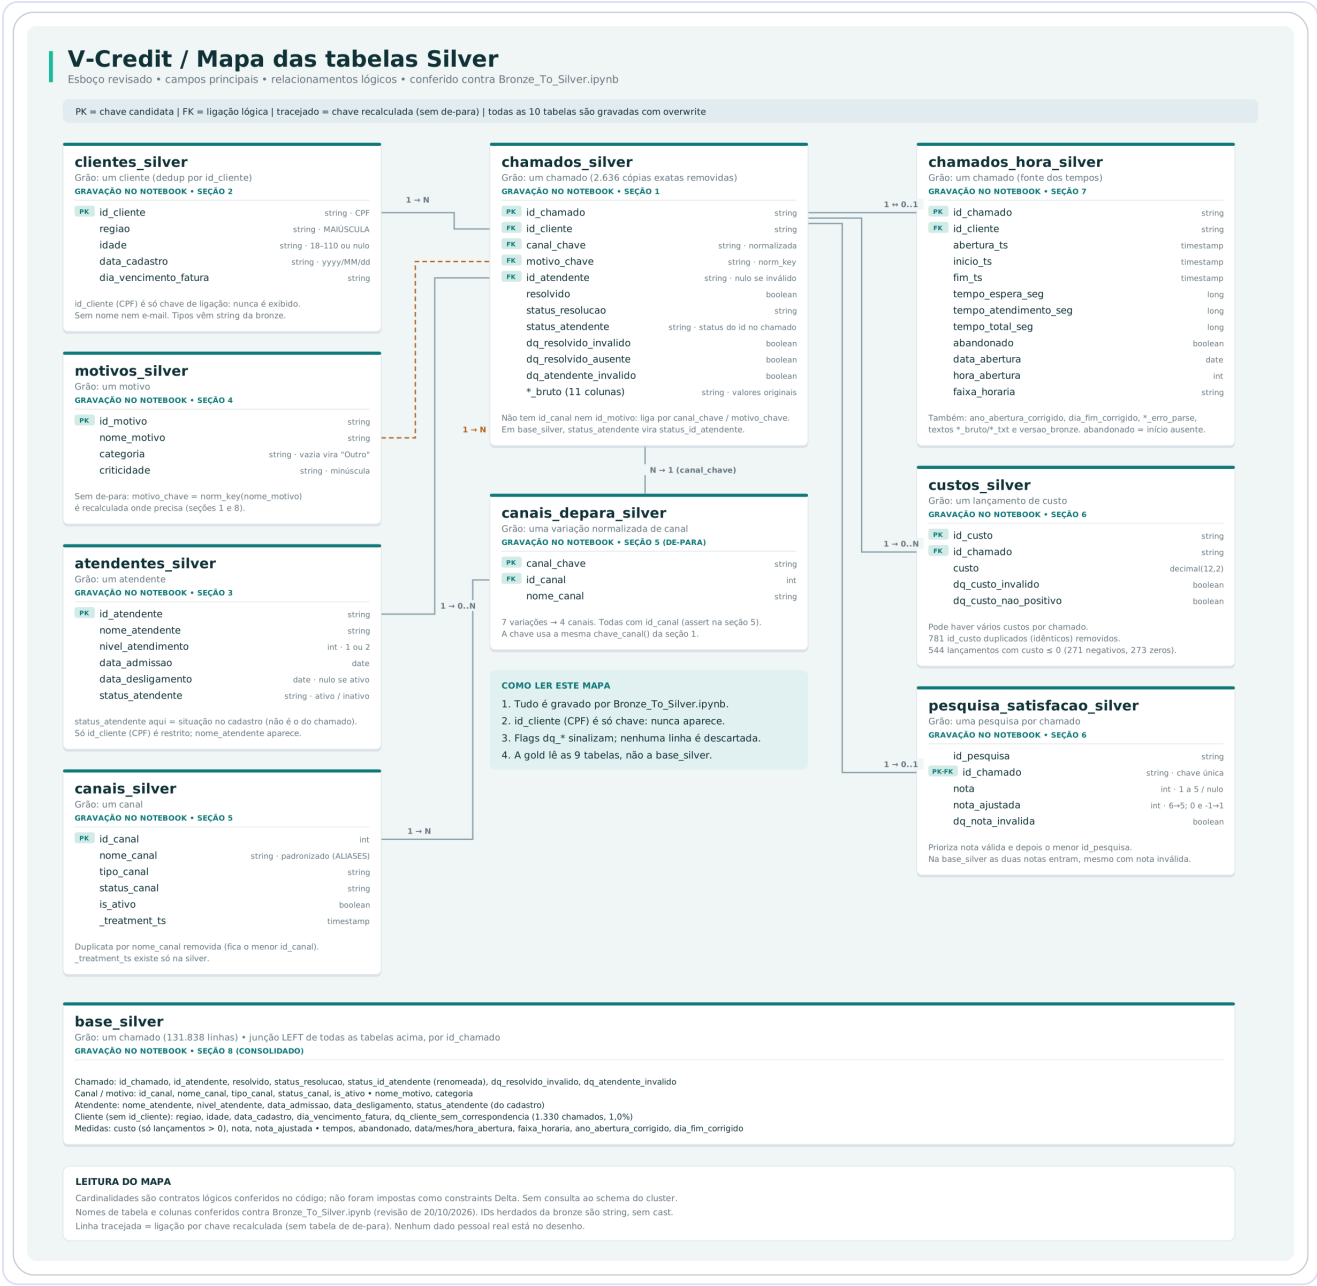


Figura 1. Modelagem da camada silver (`modelagem-silver.png`)

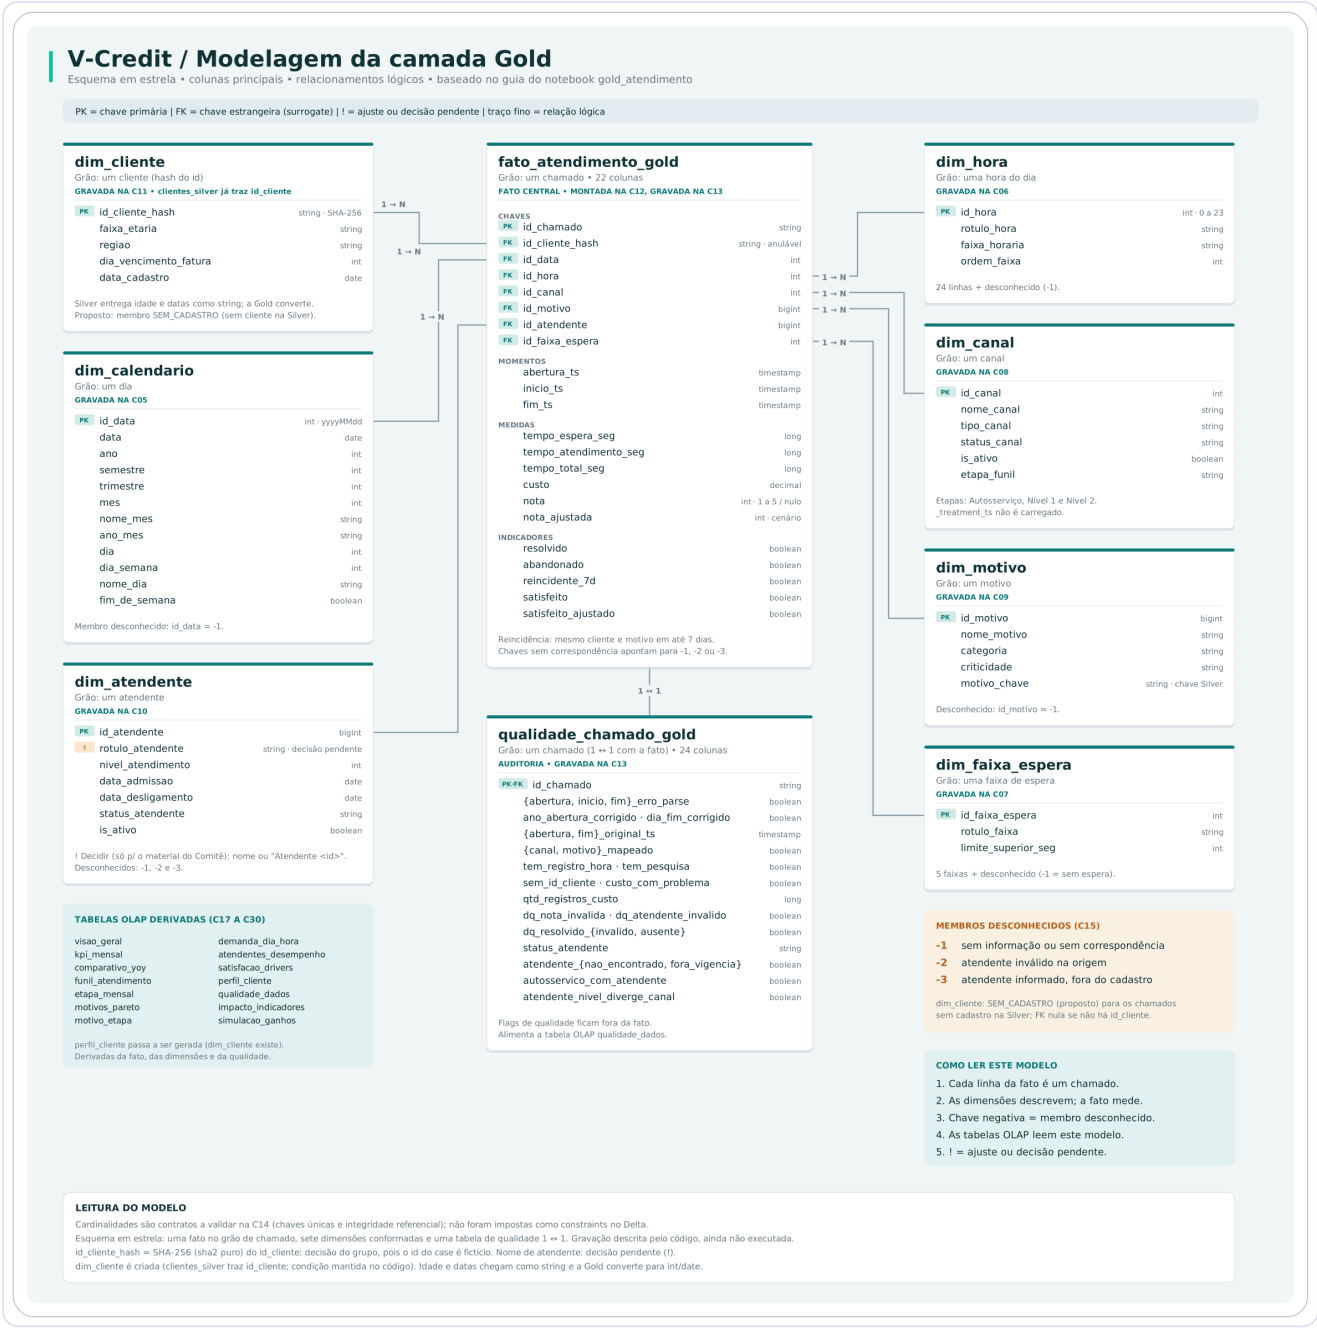


Figura 2. Modelagem da camada gold, esquema em estrela (`modelagem-gold.png`)

3 Notebooks, Job e idempotência

Entregáveis técnicos: *notebooks documentados em Databricks (Free Edition)* e *jobs automáticos configurados entre os notebooks, com pipeline idempotente*. Código em `../../medalhao/` ; arquivos de prova em `evidencias/` .

3.1 Notebooks

Todos têm a mesma estrutura: cabeçalho com o grupo, célula "Sobre este notebook" (o que faz, regras, o que grava), configuração no topo, uma seção por tabela, conferência com contagens e um **checklist antes de aplicar uma mudança** no final.

Notebook	Células	Documentação inline	Verificações que interrompem a execução
`Landing_To_Bronze.ipynb`	8	Encoding por arquivo, colunas de rastreio, caminho `file:`	— (imprime a contagem de cada tabela)
`Bronze_To_Silver.ipynb`	33	Uma seção por tabela com as regras de limpeza; checklist	Entrada vazia ou `id_chamado` ausente/duplicado (`chamados` , `chamados_hora`)
`Silver_To_Gold.ipynb`	64	Dicionário de colunas em `guia_camada_gold_vcredit_texto.pdf` ; diagrama da estrela	Chave órfã ou duplicada; fato com número de linhas ≠ chamados da silver
`Gold_To_CSV.ipynb`	10	Formato dos CSVs, ajustes do modelo de consumo, manifesto	Tabela gold ausente; chave repetida; perda de chamado na junção; órfão fora do calendário; CSV com contagem diferente da tabela

Nenhuma saída de célula exibe CPF, nome ou e-mail de cliente: são `print` s de contagem e checagens agregadas.

3.2 Ordem e dependências

```
Landing_To_Bronze  →  Bronze_To_Silver  →  Silver_To_Gold  →  Gold_To_CSV
   (8 *_raw)            (9 *_silver +         (9 dim/fato +       (pacote_powerbi.zip
                         base_silver)          14 analíticas)      no Volume)
```

3.3 Job de atualização (Databricks Workflows)

Job `visagio - job` (ID 218967712537699). Quatro tarefas de notebook em cadeia, cada uma com `run_if: ALL_SUCCESS` (uma falha interrompe as seguintes). Configuração completa em `evidencias/job-visagio.yaml` .

Item	Configuração real
Notebooks	`/Workspace/Shared/case-final-rocket-lab/medalhao/<Nome>`
Compute	Serverless, ambiente versão 6 (`Default`), `performance_target: PERFORMANCE_OPTIMIZED`

Item	Configuração real
Agendamento	`20 0 0/12 * * ?` (Quartz: segundo, minuto, hora, dia, mês, dia da semana), ou seja, 00:00 e 12:00 em America/Sao_Paulo, `UNPAUSED`
Concorrência	`max_concurrent_runs: 1`, fila ativada
Retentativa, notificação, parâmetros	Nenhum. `anonimizar_atendente` fica no padrão `false` do widget do `Gold_To_CSV`
Duração típica	7 a 8 min (maior observada: 17 min, em execução manual)

Execuções observadas (`evidencias/job-execucoes.png`): 7, todas com sucesso, das quais 5 incluem a tarefa `Gold_To_CSV` (as duas primeiras ainda não tinham essa tarefa). A lista mostra 3 execuções com gatilho **"By scheduler"** (duas em 21/10 e uma em 22/10), o que comprova o disparo automático. Elas batem com o histórico Delta de `chamados_hora_silver`: a versão 5 (22/10 02:01 UTC, 21/10 23:01 em Brasília) e a versão 6 (03:01 UTC, 22/10 00:01 em Brasília) vieram de execuções agendadas; a versão 7 (04:42 UTC, 22/10 01:42 em Brasília) foi disparada à mão com *Executar agora*.

Histórico do agendamento (informado pelo grupo). Durante os testes o Job rodou de hora em hora (cron `20 0 * * * ?`). Depois foi trocado para 12 em 12 horas (`20 0 0/12 * * ?`), que é o definitivo; a execução agendada das 23h de 21/10 só se explica pela frequência antiga.

Limites e riscos conhecidos

- Sem retentativa nem notificação por e-mail: uma falha só aparece ao abrir o Job. Como cada notebook grava tabela por tabela, uma falha no meio deixa camadas em estados diferentes até a próxima execução.
- Cada execução regrava o `pacote_powerbi.zip` no Volume: **não baixe o zip entre 12:00 e 12:10** (nem entre 00:00 e 00:10).

3.4 Idempotência: evidência

Critério do enunciado: reexecutar o pipeline sobre os mesmos dados dá o mesmo resultado, sem duplicar nem alterar registros.

Mecanismos

Camada	Mecanismo
Bronze	`overwrite` por tabela; sempre lê a mesma pasta de origem
Silver	`overwrite` por tabela; dedup determinístico por `id_chamado` / `id_custo` / `id_cliente`
Gold	`overwrite` / `CREATE OR REPLACE TABLE`; a gold não usa hora de processamento; chaves de dimensão determinísticas
Exportação	Cada CSV regravado por inteiro com linhas em ordem fixa; `checksum_linhas` (soma de `xxhash64` por linha, independente da ordem) no manifesto

a) Manifestos da exportação entre duas execuções (`evidencias/comparacao_manifestos.csv`)

Rodada	Pacote	Exportado (UTC)	Versão Delta da gold
1	`exp_20261022_012729`	22/10 01:27 (21/10 22:27 em Brasília)	2

Rodada	Pacote	Exportado (UTC)	Versão Delta da gold
2	`exp_20261022_044507`	22/10 04:45	7

As **22 tabelas** exportadas têm o mesmo número de linhas e o mesmo `checksum_linhas`. Exemplo: `fato_atendimento`, 131.838 linhas, checksum `-467904629632531319894`. A rodada 1 foi uma exportação avulsa do `Gold_To_CSV` (25 minutos depois da gravação da gold), e a gold foi regravada 5 vezes até a rodada 2 (versão Delta 2 → 7) sem mudar de conteúdo.

b) Foto de todas as tabelas `_raw`, `_silver` e `_gold` antes e depois de uma nova execução (linhas e checksum, sem `_ingestion_ts`), em `evidencias/Validacao_Idempotencia.ipynb`. Só `canais_silver` e `chamados_hora_silver` divergiram, com o mesmo número de linhas.

c) Causa e prova. Cada uma dessas duas tem uma coluna de linhagem que muda por definição a cada execução: `canais_silver._treatment_ts` (`current_timestamp()` do tratamento) e `chamados_hora_silver.versao_bronze` (versão Delta da bronze, que sobe a cada ingestão). Comparando as versões Delta 6 e 7 sem essas colunas, `EXCEPT ALL` nos dois sentidos deu **0 diferenças** nas duas tabelas.

Conclusão. O conteúdo de negócio é idêntico entre execuções. Só mudam as colunas de linhagem `_ingestion_ts` (bronze), `_treatment_ts` (`canais_silver`) e `versao_bronze` (`chamados_hora_silver`), que ficam fora da comparação de propósito.

Limites da evidência

- A prova cobre reexecução sobre os **mesmos CSVs de entrada**. Não testa mudança de entrada nem carga incremental (o enunciado não exige).
- A foto do item (b) foi tirada antes da limpeza do schema e lista 47 tabelas `_raw/_silver/_gold`: 6 delas eram testes de análise anteriores à gold final (`canal_*_gold`) e já foram removidas. Hoje o schema tem 23 tabelas `_gold`, todas criadas por `Silver_To_Gold`.

Escalabilidade. Todas as tabelas são regravadas por inteiro (`overwrite`), adequado ao volume atual (cerca de 130 mil chamados). Para volumes maiores, o caminho é carga incremental com `MERGE` e particionamento por data.

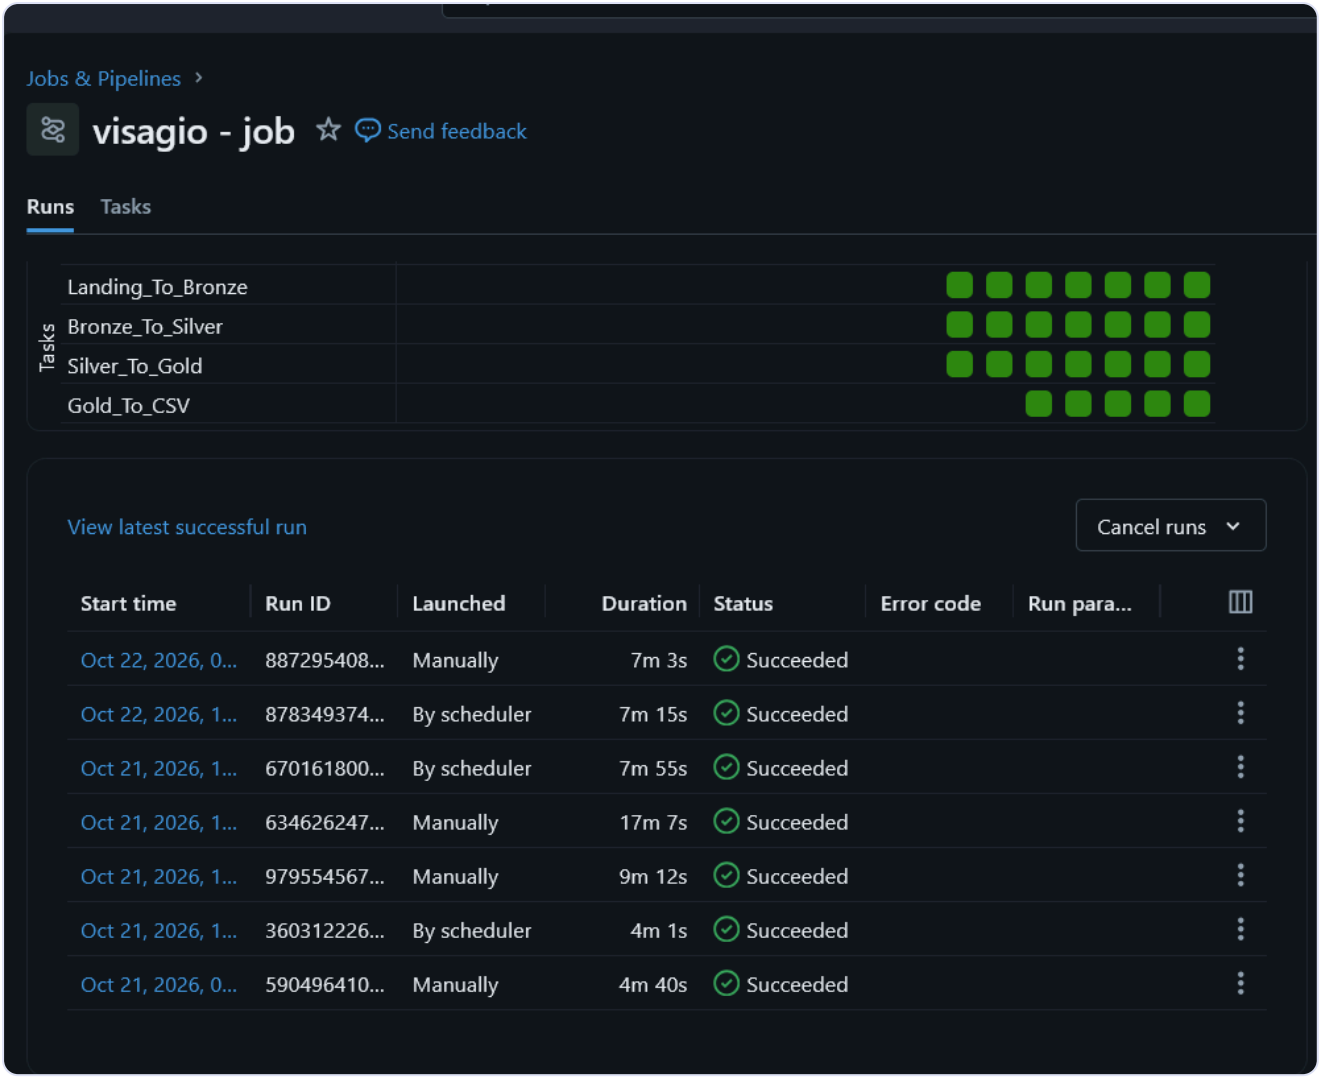


Figura 3. Lista de execuções do Job `visagio - job` no Databricks (3 execuções com gatilho "By scheduler")

Configuração do Job (YAML)

Exportada do Databricks Workflows (`docs/tecnico/evidencias/job-visagio.yaml`).

```yaml
resources:
  jobs:
    visagio_job:
      name: "visagio - job "
      schedule:
        quartz_cron_expression: 20 0 0/12 * * ?
        timezone_id: America/Sao_Paulo
        pause_status: UNPAUSED
      tasks:
        - task_key: Landing_To_Bronze
          notebook_task:
            notebook_path: /Workspace/Shared/case-final-rocket-lab/medalhao/Landing_To_Bronze
            source: WORKSPACE
          environment_key: Default
        - task_key: Bronze_To_Silver
          depends_on:
            - task_key: Landing_To_Bronze
          notebook_task:
            notebook_path: /Workspace/Shared/case-final-rocket-lab/medalhao/Bronze_To_Silver
            source: WORKSPACE
        - task_key: Silver_To_Gold
          depends_on:
            - task_key: Bronze_To_Silver
          notebook_task:
            notebook_path: /Workspace/Shared/case-final-rocket-lab/medalhao/Silver_To_Gold
            source: WORKSPACE
        - task_key: Gold_To_CSV
          depends_on:
            - task_key: Silver_To_Gold
          notebook_task:
            notebook_path: /Workspace/Shared/case-final-rocket-lab/medalhao/Gold_To_CSV
            source: WORKSPACE
      queue:
        enabled: true
      environments:
        - environment_key: Default
          spec:
            environment_version: "6"
      performance_target: PERFORMANCE_OPTIMIZED
```

4 Painel de indicadores (Power BI)

Entregável técnico: *painel de indicadores consolidado, com as principais métricas que ilustram o resultado dos tratamentos*. O Databricks Free Edition não integra com o Power BI; o caminho previsto pelo enunciado é exportar a camada gold em CSV e importar no Power BI Desktop. O `Gold_To_CSV.ipynb` faz a exportação e o painel lê as **14 tabelas analíticas** dessa exportação.

4.1 O que é e onde está

Item	Onde
Projeto PBIP (texto, versionável)	`../../powerbi/painel-v-credit/` : `Painel_Atendimento_VCredit.pbip` abre o projeto
Relatório (páginas e visuais, em JSON)	`Painel_Atendimento_VCredit.Report/definition/` (7 páginas)
Modelo semântico (tabelas, medidas, relacionamentos, parâmetro, em TMDL)	`Painel_Atendimento_VCredit.SemanticModel/definition/`
Arquivo `.pbix`	Abrir no Drive do grupo. **Não** é versionado, porque embute dados
PDF do painel (7 páginas, versão de 22/10/2026)	`evidencias/painel/painel-atendimento-v-credit.pdf`
Dados (CSV, cache `.abf`, `localSettings.json`)	**Não vão para o git**: o `.gitignore` bloqueia CSV, `.pbix`, `.zip`, o cache (`cache.abf`) e as configurações locais (`localSettings.json`) do Power BI

O PBIP guarda só definição, sem dados. Quem abre o projeto precisa apontar o parâmetro `PastaCSV` para uma exportação e **atualizar** para carregar os dados.

4.2 Fonte de dados: as 14 tabelas analíticas

O parâmetro **`PastaCSV`** (texto) deve apontar para a pasta `analiticas` de uma exportação do Job (por exemplo `exportacao_powerbi/exp_<timestamp>/analiticas`, ou a pasta `analiticas` do `pacote_powerbi.zip` descompactado; `<timestamp>` é o `pacote_id` do `_manifesto`). Cada tabela lê `<PastaCSV>\<nome>.csv` (UTF-8, vírgula; o `Text.TrimEnd` aceita a pasta com ou sem `\` no fim). No repositório o valor é um caminho genérico (`C:\caminho\para\exportacao\analiticas`) e **precisa ser trocado** em cada máquina.

CSV	Granularidade	Filtra por período
`visao_geral.csv`	1 linha, período completo	Não
`kpi_mensal.csv`	1 linha por mês	Sim
`comparativo_yoy.csv`	1 linha por mês do ano, 2025 e 2026 lado a lado	Não
`funil_atendimento.csv`	1 linha por canal, período completo	Não
`etapa_mensal.csv`	mês × etapa do funil	Sim
`motivos_pareto.csv`	1 linha por motivo	Não

CSV	Granularidade	Filtra por período
`motivo_etapa.csv`	motivo × etapa do funil	Não
`demanda_dia_hora.csv`	dia da semana × hora de abertura	Não
`atendentes_desempenho.csv`	1 linha por atendente	Não
`satisfacao_drivers.csv`	fator × valor, só chamados com nota	Não
`perfil_cliente.csv`	faixa etária ou região × etapa	Não
`qualidade_dados.csv`	1 linha por indicador de qualidade	Não
`impacto_indicadores.csv`	indicador × método de cálculo	Não
`simulacao_ganhos.csv`	cenário × motivo (o painel recalcula os totais)	Não

Além delas, o modelo tem tabelas calculadas dentro do próprio painel: `DimMes` e `DimEtapa` (eixos compartilhados), `Medidas`, `Alertas`, `Metrica Heatmap`, `Premissa A` e `Premissa B` (seletores das premissas dos cenários), `Oportunidades`, `Def_Indicadores` e `Def_Tabelas`.

4.3 As 7 páginas

#	Página	Público	O que responde
1	**Visão executiva**	Comitê Executivo	Oito cartões (chamados, custo total, custo médio, resolução, TME, TMA, CSAT e a taxa de chamados sem início de atendimento), evolução mensal, custo no funil e "pontos de atenção". O que mudou ao longo dos meses, onde o custo se concentra e o que pede atenção imediata
2	**Financeiro**	Gerente Financeiro	O custo total cresce mais rápido que o volume? Qual etapa e quais motivos concentram o custo? Quanto custa cada resolução? Traz a diferença contra os R$ 1,4 mi da entrevista e a economia anual dos cenários A e B. Avisa que **não há receita** nas tabelas
3	**Customer Success**	Coordenadora de Customer Success	O TMA subiu e a resolução caiu, em qual etapa? Quando a demanda aperta e a espera sobe (mapa de calor)? Quais atendentes e motivos pedem apoio? Inclui o desempenho por atendente contra a média do nível (só com amostra suficiente)
4	**Tecnologia e dados**	Diretor de Tecnologia	O chatbot e a URA resolvem a maior parte? Que perfis mais chegam ao humano? Quais inconsistências existem (o gráfico mostra só os defeitos acima de 5% dos chamados; indicadores informativos ficam de fora) e quanto o tratamento muda os indicadores (`qualidade_dados` e `impacto_indicadores`)? Registra a decisão de privacidade (hash SHA-256 sem segredo)
5	**Marketing e CSAT**	Diretora de Marketing	O CSAT de 2026 difere do de 2025? Quanto dos chamados responde à pesquisa? Que fatores (espera, reincidência, resolução, etapa, canal, motivo, faixa horária) se associam a notas baixas? Lê como associação, não causalidade
6	**Oportunidades**	Comitê Executivo	Quais iniciativas trazem mais ganho, com quais premissas e o que ainda falta medir. Seletores das premissas de deflexão (A) e de redução de reincidência (B); sem seleção valem 20% e 30%

#	Página	Público	O que responde
7	**Definições**	Todos	Como cada indicador é calculado, de qual tabela vem e a granularidade de cada tabela

Cada página tem um quadro "Sobre esta página" (objetivo, público, perguntas e ações possíveis), e as páginas 1, 2, 3 e 5 têm filtro de período.

4.4 Como abrir

1. Baixe uma exportação do Job (`pacote_powerbi.zip` do Volume `exportacao_powerbi`) e descompacte **fora do repositório**.
2. No Power BI Desktop, **abra o arquivo** `powerbi/painel-v-credit/Painel_Atendimento_VCredit.pbip`. Se o Desktop não abrir o formato, habilite o recurso de projeto (`.pbip`) em *Opções → Recursos em versão prévia*.
3. **Transformar dados → Gerenciar parâmetros →** `PastaCSV` : informe a pasta `analiticas` descompactada.
4. **Atualizar**. Confira os cartões abaixo.
5. Para entregar, salve também como `.pbix` no drive do grupo e exporte PDF e prints das páginas.

Não baixe o zip entre 12:00 e 12:10 (nem entre 00:00 e 00:10): o Job regrava o pacote nesses horários.

4.5 Conferência dos cartões (período completo)

No período completo, os cartões leem `visao_geral` (valores exatos). Com filtro de período, o painel usa a média dos meses ponderada pelos chamados (CSAT, pelas respostas), que é uma aproximação. O formato do cartão pode exibir o valor arredondado.

Cartão	Valor esperado
Chamados	131.838
Custo total	R$ 1.450.617,85
Custo médio por chamado	R$ 11,18
Taxa de resolução	50,88%
TME	3,60 min
TMA	11,03 min
CSAT	71,57%
SEM INÍCIO DE ATENDIMENTO (PROXY), cartão das páginas 1 e 3	2,59%
Economia anual, cenário A (páginas 2 e 6)	R$ 30,9 mil (o cartão mostra R$ 30.863)
Economia anual, cenário B (páginas 2 e 6)	R$ 258,1 mil (o cartão mostra R$ 258.065)

Os oito primeiros são os valores de `visao_geral.csv` (pacote `exp_20261022_012729`) e os dois cenários vêm de `simulacao_ganhos.csv` ; com a mesma base eles devem se repetir em qualquer exportação nova. **Os cenários A e B se sobrepõem (98% da base de A já está em B): não somar.** Se o custo aparecer 100 vezes

maior (por exemplo `145061785`), a localidade de leitura do CSV está errada: use inglês (Estados Unidos) para números e datas.

4.6 Limitações

- **Só as 14 tabelas agregadas, sem estrela.** O painel não usa as tabelas do modelo (`modelo/fato_atendimento.csv` e dimensões) e, por isso, não detalha por chamado. Os únicos relacionamentos são entre as tabelas mensais e de etapa e as dimensões `DimMes` e `DimEtapa`; as demais tabelas se ligam por medidas.
- **Cenários A e B não somam.** 98,1% da base do cenário A (12.172 de 12.411 chamados) já está na base do B (conferido no Databricks em 22/10/2026). Cada cartão mostra um cenário; somar os dois conta a mesma economia duas vezes. As premissas de 20% e 30% são hipóteses do grupo.
- **Abandono é um proxy.** O indicador conta chamados **sem hora de início de atendimento**; não confirma que o cliente desistiu. Por isso os cartões, eixos, títulos e alertas se chamam "sem início de atendimento (proxy)"; no mapa de calor a métrica é "Sem início (proxy)". Só os **nomes internos** das medidas e das colunas ainda usam "abandono" (`Abandono`, `Abandono CS`, `pct_abandono` etc.), e a definição na página 7 explica a equivalência.
- **Sem receita.** Não dá para dizer se o custo acompanha a receita, a preocupação do Gerente Financeiro.
- **Valores de período parcial são aproximados** (média de médias ponderada).
- **Nomes de atendentes mantidos; base fictícia.** A página "Customer Success" mostra `rotulo_atendente` (`anonimizar_atendente = false`, o padrão do `Gold_To_CSV`). Decisão do grupo, registrada aqui para não parecer esquecimento.
- **Campo atendente em chamados de autosserviço.** Vem preenchido em 99,4% dos chamados de URA e chatbot, onde não deveria haver atendente humano. Até confirmarmos o significado do campo (pergunta à V-Credit, em `../analitico/confiabilidade-dos-dados.md`), os números por atendente são indicativos e a tabela da página "Customer Success" é uma associação, não um ranking de desempenho.
- **Tabelas e gráficos com rolagem aparecem cortados no PDF.** Nos 3 gráficos de linha pequenos da Visão executiva, o último mês (jul/26) fica fora da janela do PDF; os valores de jul/26 estão nos alertas e no painel interativo (CSAT 56,7%, sem início 3,8%). O painel interativo mostra todas as linhas e todos os meses.
- **Prevenção (site e app)** não existe nos dados; o painel não a mostra.

5 Ambiente e operação no Databricks

Como o case V-Credit está organizado no workspace do grupo (Databricks Free Edition: só serverless, SQL warehouse 2X-Small, cota diária de uso). Os nomes de menus podem variar um pouco na interface.

O código oficial fica no GitHub (`main` , pasta `../medalhao/`). O Databricks é o ambiente de execução: o que roda aqui deve vir de um arquivo já revisado no repositório. **Sem Git folder** por enquanto: o fluxo é editar localmente → *Workspace* → *Import* → rodar e testar → trazer a versão final de volta ao repositório.

5.1 Estrutura real

```
Workspace/Shared/case-final-rocket-lab/
├── dados/        os 8 CSVs originais (Workspace; ver 2 sobre o esquema file:)
├── medalhao/     Landing_To_Bronze, Bronze_To_Silver, Silver_To_Gold, Gold_To_CSV  (= repositório:
medalhao/)
└── resultados/   prints e exportações de resultados                              (= repositório:
resultados/)

Unity Catalog:  catálogo dados_vcredit › schema default
├── <tabela>_raw      bronze (8)
├── <tabela>_silver   silver (9) + base_silver
├── <tabela>_gold     gold: 7 dimensões, fato, qualidade e 14 analíticas
└── Volume exportacao_powerbi   saída de Gold_To_CSV (pacote_powerbi.zip)
```

Mantenha o nome do arquivo igual ao do repositório, para não perder o rastro de qual versão está onde.

5.2 Como os dados são lidos

`spark.read` em pasta do Workspace só funciona em leitura distribuída com o **esquema `file:` explícito** no caminho (`file:/Workspace/Shared/case-final-rocket-lab/dados/<arquivo>.csv`); sem ele dá erro de permissão (`INSUFFICIENT_PERMISSIONS ... SELECT on any file`). O `Landing_To_Bronze.ipynb` usa uma constante `BASE_PATH` fixa. Se os CSVs migrarem para um Volume, troque a constante e tire o prefixo `file:` .

Encoding: `clientes.csv` e `Chamados_Hora.csv` são `ISO-8859-1` (cp1252); os demais, `UTF-8` . O arquivo original era `Chamados_Hora.CSV` ; o grupo padronizou para `.csv` , e a tabela de destino é sempre minúscula (`chamados_hora_raw`).

5.3 Passo a passo (montar do zero)

1. **Pastas**: em *Workspace > Shared*, crie `case-final-rocket-lab` e, dentro dela, `dados` , `medalhao` e `resultados` .
2. **Notebooks**: em *Import* (menu da pasta), importe os 4 `.ipynb` de `medalhao/` do repositório.
3. **Dados**: suba os 8 CSVs em `dados/` com os nomes originais (em minúsculo).
4. **Destino**: o catálogo `dados_vcredit` e o schema `default` já existem; o `Gold_To_CSV` cria o Volume `exportacao_powerbi` (`CREATE VOLUME IF NOT EXISTS`).
5. **Acesso**: compartilhe `Shared/case-final-rocket-lab` com **Can Edit** (ou **Can Run**). Nas tabelas/Volume, conceda `USE SCHEMA` , `SELECT` e `READ VOLUME` a quem precisar. Os dados são confidenciais: não compartilhe fora do grupo.

6. **Executar na ordem** (ou pelo Job, ver `tecnico/notebooks-e-jobs.md`): `Landing_To_Bronze` → `Bronze_To_Silver` → `Silver_To_Gold` → `Gold_To_CSV`.
7. **Baixar o pacote**: *Catálogo* → *`dados_vcredit`* → *`default`* → *Volumes* → *`exportacao_powerbi`* → *`pacote_powerbi.zip`* → *Baixar*. Guarde em `data/powerbi/` (fora do git).

5.4 Conferência dos números

Depois de rodar as camadas, confira:

Tabela	Linhas
bronze `chamados_raw` / silver `chamados_silver`	134.474 / 131.838 (2.636 duplicatas idênticas removidas)
`chamados_hora`	131.838
`clientes`	47.705
`custos` bronze	131.069 (781 duplicatas removidas na silver)
`pesquisa_satisfacao`	81.021
`base_atendentes` / `base_motivos` / `canais`	25 / 14 / 4
gold: `fato_atendimento_gold`, `qualidade_chamado_gold`	131.838 cada
gold: dimensões	calendário 731, hora 25, faixa de espera 6, canal 5, motivo 15, atendente 28, cliente 47.705
`visao_geral_gold`	custo total R$ 1.450.617,85; CSAT 71,57%; TME 3,60 min; TMA 11,03 min; resolução 50,88%; abandono 2,59%

Se algo divergir, **não ajuste o código para forçar o número**: anote a diferença e investigue (encoding, formato dos timestamps, modo ANSI do serverless).

5.5 Problemas comuns

Sintoma	Causa provável	O que fazer
`INSUFFICIENT_PERMISSIONS ... SELECT on any file`	`spark.read` numa pasta do Workspace sem `file:`	Usar `file:/Workspace/...` no caminho
`Path does not exist`	Caminho com texto de exemplo ou nome errado	Copiar o caminho pelo Catalog / navegador de arquivos
Erro de permissão em tabela ou Volume	Falta `USE SCHEMA`, `SELECT` ou `READ VOLUME`	Pedir a quem criou
Acentos quebrados	Encoding errado (`clientes` e `Chamados_Hora` são ISO-8859-1)	Conferir o dicionário `ARQUIVOS` do `Landing_To_Bronze`
`Tabelas Gold ausentes ... Rode o Silver_To_Gold antes`	`Gold_To_CSV` rodou antes da gold	Respeitar a ordem das 4 etapas

Sintoma	Causa provável	O que fazer
Cota diária esgotada	Free Edition	Evitar rodar o pipeline inteiro várias vezes sem necessidade

5.6 Regras de segurança e sincronia

- Nunca suba CSV, `.env` ou token para o GitHub. Nunca imprima `id_cliente` (CPF), nome ou e-mail de `clientes` em célula, doc ou print.
- Evite `collect()` / `toPandas()` em tabelas grandes (~130 mil linhas nas maiores); agregue no Spark antes de `display()`.
- Não edite no Databricks um arquivo que também é editado localmente. Mudou algo aqui? Leve ao GitHub por PR; mudou no repositório? Reimporte a versão revisada.
- Quando terminar de testar uma mudança, traga a versão final de volta para o repositório.
- Remova a pasta `dados` do Workspace quando o projeto terminar (os arquivos têm CPF, nome e e-mail).

5.7 Checklist

- ☐ Pastas `dados`, `medalhao` e `resultados` em `Shared/case-final-rocket-lab`
- ☐ 4 notebooks importados de `medalhao/`
- ☐ 8 CSVs em `dados/` com os nomes originais
- ☐ Acesso concedido ao grupo (pasta, tabelas, Volume)
- ☐ Pipeline rodado na ordem; contagens conferidas (seção 4)
- ☐ `pacote_powerbi.zip` baixado para `data/powerbi/`

6 Histórico de revisões da silver e da gold

Registro histórico. Resume as rodadas de revisão da silver e da gold feitas em 20 e 21/10/2026 (diagramas, notebooks e guia da gold). O estado atual está no capítulo 2; os itens pendentes citados nas rodadas já foram resolvidos.

6.1 Correções aplicadas após a revisão (20/10/2026)

Notebooks

- `Bronze_To_Silver.ipynb`: textos desatualizados (cabeçalho, seção 7, seção 8) corrigidos; `base_silver` agora traz `nota_ajustada` também quando `nota` é inválida; `base_silver.custo` soma só lançamentos > 0 (igual à gold); ~~o~~ ~~`display`~~ ~~de~~ ~~`atendentes_silver`~~ ~~não mostra mais~~ ~~`nome_atendente`~~ (**revertido na terceira rodada**). **Para refletir na tabela, rodar de novo ao menos a seção 8** (as demais seções não mudaram de resultado).
- `Landing_To_Bronze.ipynb`: o `display` não mostra mais `id_cliente` (CPF) (a parte sobre `nome_atendente` foi revertida na terceira rodada); as saídas salvas da célula de verificação foram apagadas (continham CPF). Não é preciso reingerir.

`modelagem-silver.png` (refeito)

- Todas as tabelas agora marcadas como gravadas por seção do notebook; sumiram os selos "PROPOSTA", "TODO", "AJUSTAR CHAVE" e "UNIFICAR NOMES".
- `chamados_silver`: colunas reais (`canal_chave`, `motivo_chave`, `status_resolucao`, `status_atendente`, flags `dq_*`, `*_bruto`); removidos `id_canal` / `id_motivo` / `canal_original` / `motivo_original`.
- `clientes_silver`: `id_cliente` (CPF) é a chave; tipos reais (`data_cadastro` string `yyyy/MM/dd`; idade e vencimento string).
- Nomes corrigidos: `motivos_silver` (não `base_motivos_silver`) e `canais_depara_silver` (não `canais_de_para`).
- `pesquisa_satisfacao_silver`: relação com chamados corrigida para 1 → 0..1.
- Incluída a `base_silver` (junção final, `status_id_atendente`, `dq_cliente_sem_correspondencia`).
- Ligações: a de `motivos_silver` fica tracejada porque a chave é recalculada (não existe de-para de motivo).

`modelagem-gold.png` (refeito)

- `dim_cliente` deixou de ser "condicional": `clientes_silver` já traz `id_cliente`. `perfil_cliente` deixou de depender de algo que faltava. Notas sobre conversão de tipos (idade e datas chegam como string).
- `id_cliente_hash` marcado com `!` e descrito como HMAC-SHA256 com segredo (o `sha2` puro de um CPF é reversível).
- Proposto membro `SEM_CADASTRO` na `dim_cliente` para os 1.330 chamados (1,0%) sem cliente na silver.
- `dim_atendente`: o diagrama dizia "sem nome do atendente" e o guia usa o nome — agora marcado com `!` como **decisão pendente** (nome real ou "Atendente "); redação ajustada na quarta rodada (vale só para o material do Comitê).
- **O que não mudou:** colunas da fato (22) e da qualidade (24), demais dimensões e tabelas OLAP.

Pendente

- `guia_camada_gold_vcredit_texto.pdf` segue desatualizado; o que trocar está em `ajustes_gold_pdf_e_diagramas.md` (seção B). Decisões em aberto: nome do atendente e `status_atendente` (mantido sem renomear em `chamados_silver`).

6.2 Segunda rodada de correções (21/10/2026) — já commitadas na main

Comparando os arquivos desta pasta com o estado real do projeto, achei e corrigi mais 4 pontos, diretamente nos notebooks originais (`bronze/Landing_To_Bronze.ipynb` e `silver/Bronze_To_Silver.ipynb`) — as cópias aqui na pasta foram atualizadas pra ficar idênticas:

- **CPF exposto de verdade (achado crítico)**: a célula de verificação da bronze fazia `display(tabela.limit(5))` pra todas as tabelas menos `clientes` — mas `chamados` e `Chamados_Hora` também têm `id_cliente` / `ID_Cliente` (o mesmo CPF). Como o notebook já tinha rodado no Databricks, CPFs reais foram exibidos na saída dessa célula. Corrigido: a amostra agora sempre tira `id_cliente` e `nome_atendente`, em qualquer tabela. As saídas antigas (com CPF) foram apagadas do notebook local.
- O bug do `nota_ajustada` (ponto já citado acima) foi de fato aplicado — validei rodando localmente: foi de 73.383 pra 74.592 em `base_silver`, batendo com o valor correto de `pesquisa_satisfacao_silver`.
- O filtro de custo `> 0` também foi validado: `com custo` em `base_silver` caiu de 130.288 pra 129.744, diferença de 544 — bate exatamente com os 544 custos ≤ 0 já documentados (271 negativos + 273 zero).
- `Bronze_To_Silver.ipynb` tinha saídas HTML de tabela embutidas (1,7 MB) — removidas num commit à parte (os `print`s de contagem continuam intactos).

Essas correções já foram commitadas direto na `main` (commits `a31da59`, `26dc328`, `8e88707`) — não é mais trabalho pendente de branch/PR. Os dois notebooks desta pasta (`Landing_To_Bronze.ipynb`, `Bronze_To_Silver.ipynb`) são cópias exatas do que está na `main` agora.

6.3 Terceira rodada (21/10/2026) — nome_atendente volta a aparecer

Importante para quem for gerar/atualizar os diagramas e o PDF a partir daqui: a rodada anterior tinha escondido `nome_atendente` (tratando como "dado pessoal") tanto na verificação da bronze quanto no `display` da seção 3 da silver. Isso foi **revertido** (commit `1e962c0`) — `nome_atendente` volta a aparecer normalmente nos dois notebooks e em `base_silver`.

Motivo: a regra de dado pessoal do projeto é específica sobre `clientes` (CPF/nome/e-mail) — `nome_atendente` nunca esteve nela, e o grupo já usa nome/identificação de atendente abertamente em `analises/top_atendentes.md`. A ocultação anterior foi uma suposição acrescentada durante uma revisão, não uma regra confirmada do projeto.

O que isso muda nos diagramas/PDF, se forem regenerados:

- `modelagem-silver.png`: `atendentes_silver` deixa de dizer "`nome_atendente` nunca é exibido nas saídas do notebook" — ele **é** exibido (seção 3 e `base_silver`). Só `id_cliente` (CPF) continua nunca sendo exibido em nenhuma célula.
- `modelagem-gold.png` / `guia_camada_gold_vcredit_texto.pdf`: o item marcado com `!` sobre "nome real ou rótulo anônimo" em `dim_atendente` **continua em aberto** — isso não muda. A decisão de mostrar o nome completo ou um rótulo tipo "Atendente 4" é só para o material que for pro Comitê Executivo (gold/apresentação), não para bronze/silver. Não há decisão tomada ainda sobre a gold.

6.4 Quarta rodada (21/10/2026) — diagramas alinhados à terceira rodada

`modelagem-silver.png` e `modelagem-gold.png` foram **regenerados** para refletir o que a terceira rodada decidiu. Os notebooks não foram alterados.

- `modelagem-silver.png`:
  - `atendentes_silver` não diz mais que `nome_atendente` nunca é exibido. A coluna aparece como `string` comum e a nota agora diz: "Só `id_cliente` (CPF) é restrito; `nome_atendente` aparece."
  - Na `base_silver`, saiu o "(dado pessoal)" ao lado de `nome_atendente`.
  - `custos_silver`: nota nova com os 544 lançamentos de custo ≤ 0 (271 negativos, 273 zeros), que ficam fora da soma de `custo` na `base_silver`.
- `modelagem-gold.png`:
  - `dim_atendente`: a nota do `!` passou a dizer que a decisão (nome real ou "Atendente ") vale **só para o material do Comitê**. Continua em aberto; nenhuma decisão foi tomada.
- `ajustes_gold_pdf_e_diagramas.md`: itens A-6 e B-9 reescritos no mesmo sentido (sem tratar o nome como dado pessoal).
- **Supera** os trechos da seção "Correções aplicadas após a revisão (20/10/2026)" que falavam em esconder `nome_atendente` ou chamá-lo de "dado pessoal".

Pendente

- ~~`guia_camada_gold_vcredit_texto.pdf` continua sem correção~~ **Refeito em 21/10/2026** com todos os ajustes da seção B (o item 1, "mais 120", era falso alarme). O PDF novo foi reconstruído do zero (mesmo conteúdo e ordem; visual simples) e termina com a seção "Alterações desta versão".
- Decisão do grupo: nome real ou rótulo anônimo do atendente no material do Comitê.

6.5 Quinta rodada (21/10/2026) — Silver_To_Gold.ipynb chegou, revisado

O notebook da gold **passou a existir** nesta rodada (não existia antes, só o guia em PDF). Revisei célula por célula contra as 9 tabelas silver reais. No geral está muito bem feito e bate com o PDF: resolução de `id_atendente` (-1/-2/-3) correta, `fato_atendimento_gold` com as 22 colunas certas, `qualidade_chamado_gold` com as 24, custo somando só `> 0`, nomes de tabela (`atendentes_silver`, `motivos_silver`, `canais_depara_silver`) todos corretos.

Achei 2 pontos:

1. **`id_cliente_hash` usava `sha2` puro, sem HMAC/segredo** — o que contradizia o que o próprio PDF (`guia_camada_gold_vcredit_texto.pdf`) e o `ajustes_gold_pdf_e_diagramas.md` (item A-3) diziam que deveria ser feito. **Decisão do grupo: manter `sha2` puro mesmo** — o `id_cliente` do case é dado fictício, não CPF real de ninguém, então o risco que justificava o HMAC não se aplica. Já corrigi:
   - `Silver_To_Gold.ipynb` (células 5 e 21): comentário explicando a decisão (o código já estava certo, só não tinha o porquê documentado).
   - `ajustes_gold_pdf_e_diagramas.md`: item A-3 e B-8 atualizados pra registrar a decisão.
   - **Ainda faltam** (próxima rodada): `modelagem-gold.png` (tirar "HMAC-SHA256" e o `!` de `id_cliente_hash` em `dim_cliente`, e a frase correspondente em "Leitura do modelo") e `guia_camada_gold_vcredit_texto.pdf` (seção "Privacidade", tirar a menção a segredo).

2. **`dim_cliente_gold.data_cadastro` e `dia_vencimento_fatura` continuavam como texto** — decisão do grupo: corrigir o notebook (não a documentação). Já corrigido e validado localmente (`célula 21`): `data_cadastro` vira `date` (`to_date(data_cadastro, 'yyyy/MM/dd')`) e `dia_vencimento_fatura` vira `int` (`try_cast(... as int)`), tratando valor nulo/inválido como `NULL` em vez de quebrar. O PDF já descrevia esse comportamento certo — não precisou mudar nada nele. **Ainda falta**: conferir se `modelagem-gold.png` já mostra os tipos certos em `dim_cliente` (sem `!` de pendência nesses dois campos).

6.6 Sexta rodada (21/10/2026) — diagrama gold e PDF alinhados à decisão do hash

- `modelagem-gold.png` : `id_cliente_hash` em `dim_cliente` agora é `PK` com tipo `string · SHA-256` (sem `!`); `data_cadastro` é `date` e `dia_vencimento_fatura` é `int` (já estavam assim, sem pendência); a nota de leitura diz que o hash é `sha2` puro por decisão do grupo (id fictício no case) e que a Gold converte idade e datas. Continuam como propostas/pendências: membro `SEM_CADASTRO` e nome do atendente no material do Comitê.
- `guia_camada_gold_vcredit_texto.pdf` (18 págs.): removidas todas as menções a HMAC/segredo; a regra de privacidade descreve o `sha2` puro e o motivo. A seção final "Alterações desta versão" foi atualizada.
- **Correção de um excesso meu na versão anterior do PDF:** eu tinha escrito que `dim_cliente` deixava de ser condicional e que `DIM_CLIENTE_CRIADA` sumia, mas o `Silver_To_Gold.ipynb` mantém a condição (hoje sempre atendida). O PDF voltou a descrever a condição, só sem o aviso "hoje não é criada".
- O notebook não cria membro desconhecido para clientes: os 1.330 chamados sem cadastro recebem um hash que não casa com a `dim_cliente` e ficam fora de `perfil_cliente` . O PDF agora diz isso como está; `SEM_CADASTRO` segue proposta.

PROCESSO DO GRUPO

7 Convenções de Git

Regras de colaboração do grupo. O fluxo com o Databricks (sem Git folder por enquanto) está em `CLAUDE.md`.

7.1 Regra geral

- **Nunca** trabalhe direto na `main` — abra Pull Request e peça revisão de outra pessoa do grupo.
- Exceção já usada: como o repositório estava vazio, o primeiro push (reorganização inicial) foi direto na `main`. Isso não se repete: toda mudança a partir de agora passa por branch + PR.
- Antes de pushar: sem CSV, sem `.zip` / `.pbix` com dados (o pacote do Power BI fica em `data/powerbi/`, fora do git), sem dado pessoal (CPF/nome/e-mail) em output de célula.

7.2 Branches

Uma branch por pessoa/tarefa, criada a partir da `main` atualizada: `git switch -c <tipo>/<nome>-<assunto>`. Mesmo prefixo dos commits (veja abaixo), por exemplo:

- `feat/milton-custo-por-nivel` — nova análise ou notebook.
- `update/juan-chamados-hora-picos` — evolução de algo que já existe.
- `fix/yuri-parsing-data-cadastro` — correção de bug ou limpeza.
- `docs/cris-checklist-enunciado` — só documentação.
- `chore/richard-organiza-pastas` — organização, configs, sem mudar análise.

7.3 Commits

Commits pequenos, seguindo Conventional Commits: `<tipo>: <descrição no imperativo>`. Tipos usados no projeto: `feat` (nova análise/funcionalidade), `update` (evolução de algo existente), `fix` (correção de bug/limpeza), `docs` (documentação), `chore` (organização, configs, sem mudar análise). Exemplos: `feat: adiciona analise de custo por canal`, `update: refina faixas de tempo de espera`, `fix: corrige parsing de data cp1252 em clientes`, `docs: atualiza checklist do enunciado`.

7.4 Pull Requests

- Título no mesmo padrão do commit (`tipo: descrição`); descrição curta do que mudou e por quê.
- Peça revisão de **pelo menos 1 outra pessoa** do grupo antes do merge — especialmente se tocar em regra de limpeza (atualize `docs/analitico/confiabilidade-dos-dados.md` e, se mudar número, o arquivo de `resultados/` correspondente no mesmo PR) ou em definição de KPI (`CLAUDE.md`).
- Antes de abrir o PR, confira: `git status --ignored` sem CSV/segredo e nenhuma saída de célula com dado pessoal.
- PR pequeno e focado numa tabela/tarefa — mais fácil de revisar que um PR com o trabalho de várias pessoas juntas.
- Prefira *squash merge* para manter o histórico da `main` limpo (um commit por PR).

ANEXOS

8 Anexo A — Capturas do painel

Capturas das 7 páginas do painel Power BI, na versão entregue em 22/10/2026. O PDF original está em `docs/tecnico/evidencias/painel/painel-atendimento-v-credit.pdf`. Tabelas e gráficos com rolagem aparecem cortados no PDF; o painel interativo mostra todas as linhas e todos os meses.

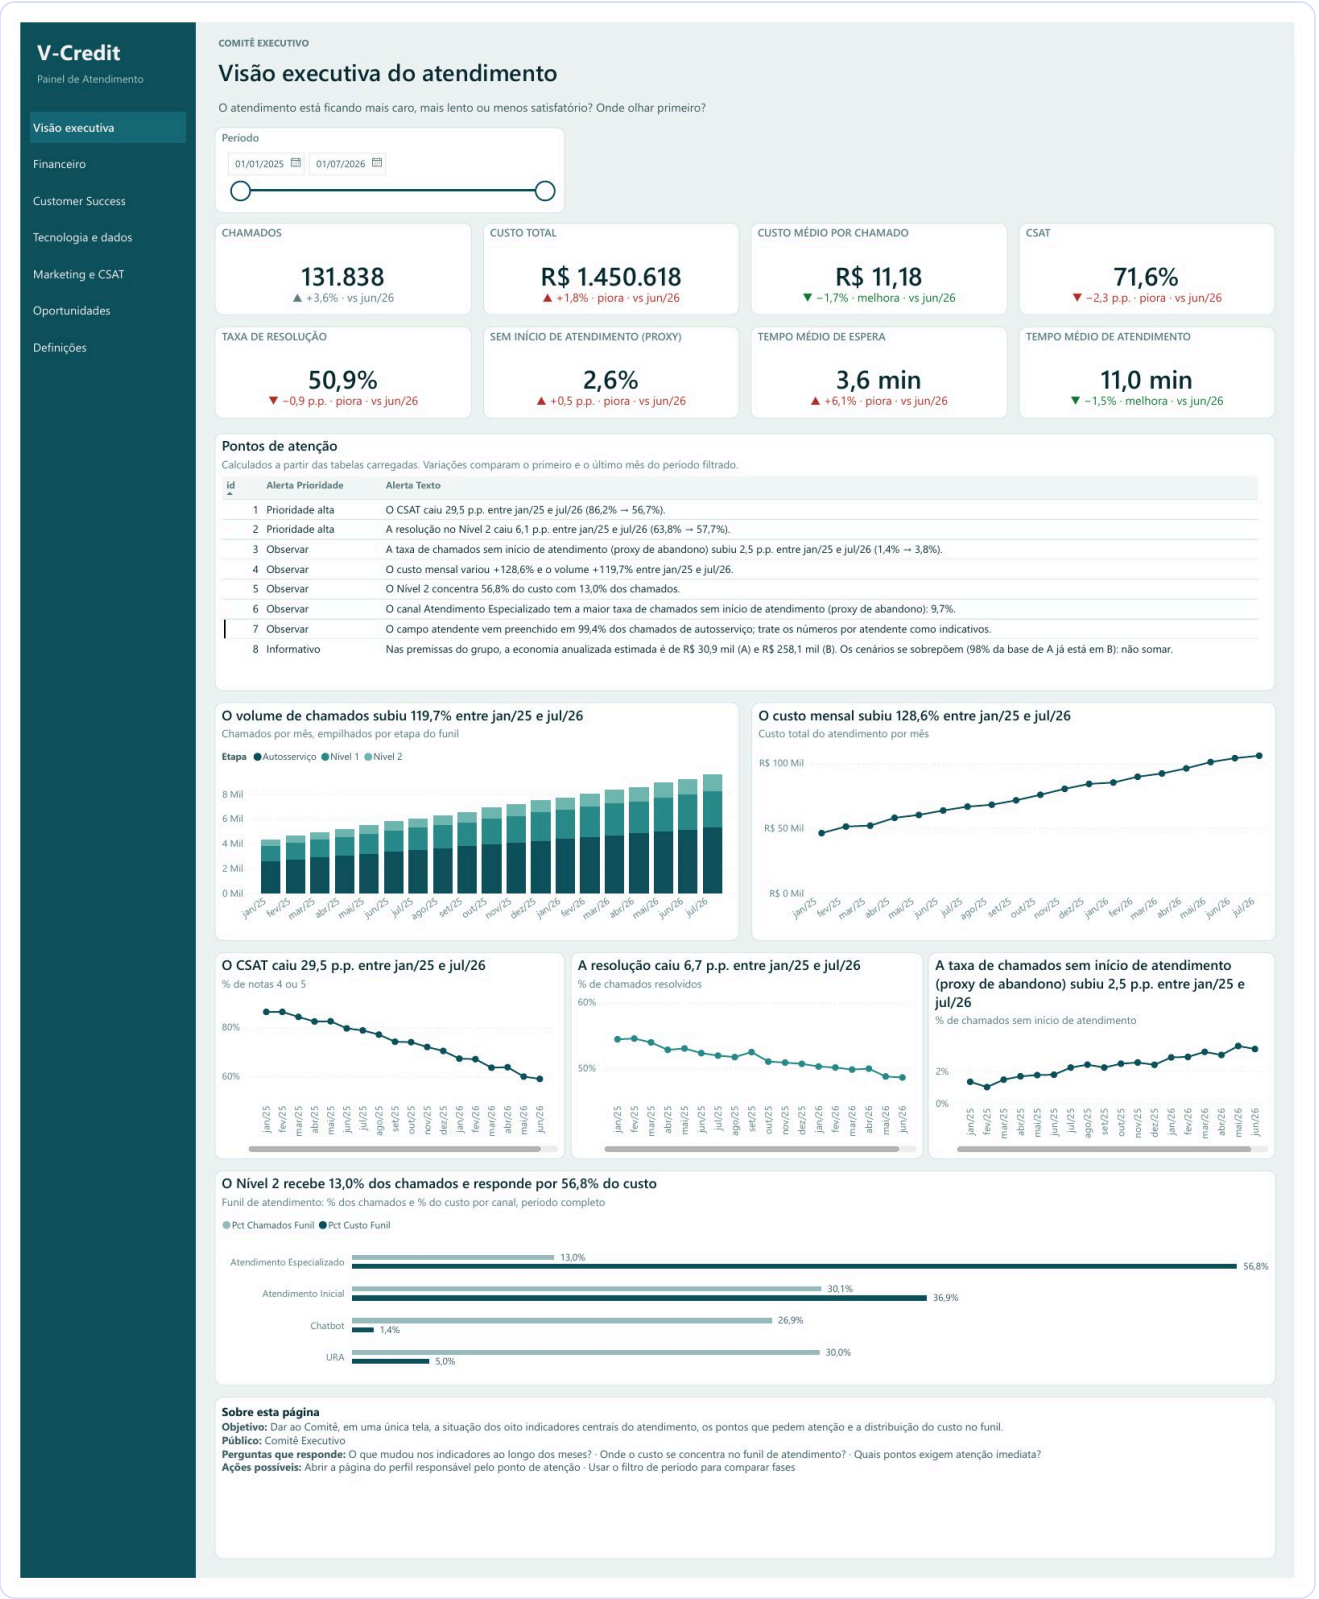


Figura 4. Painel, página 1: Visão executiva (versão de 22/10/2026)

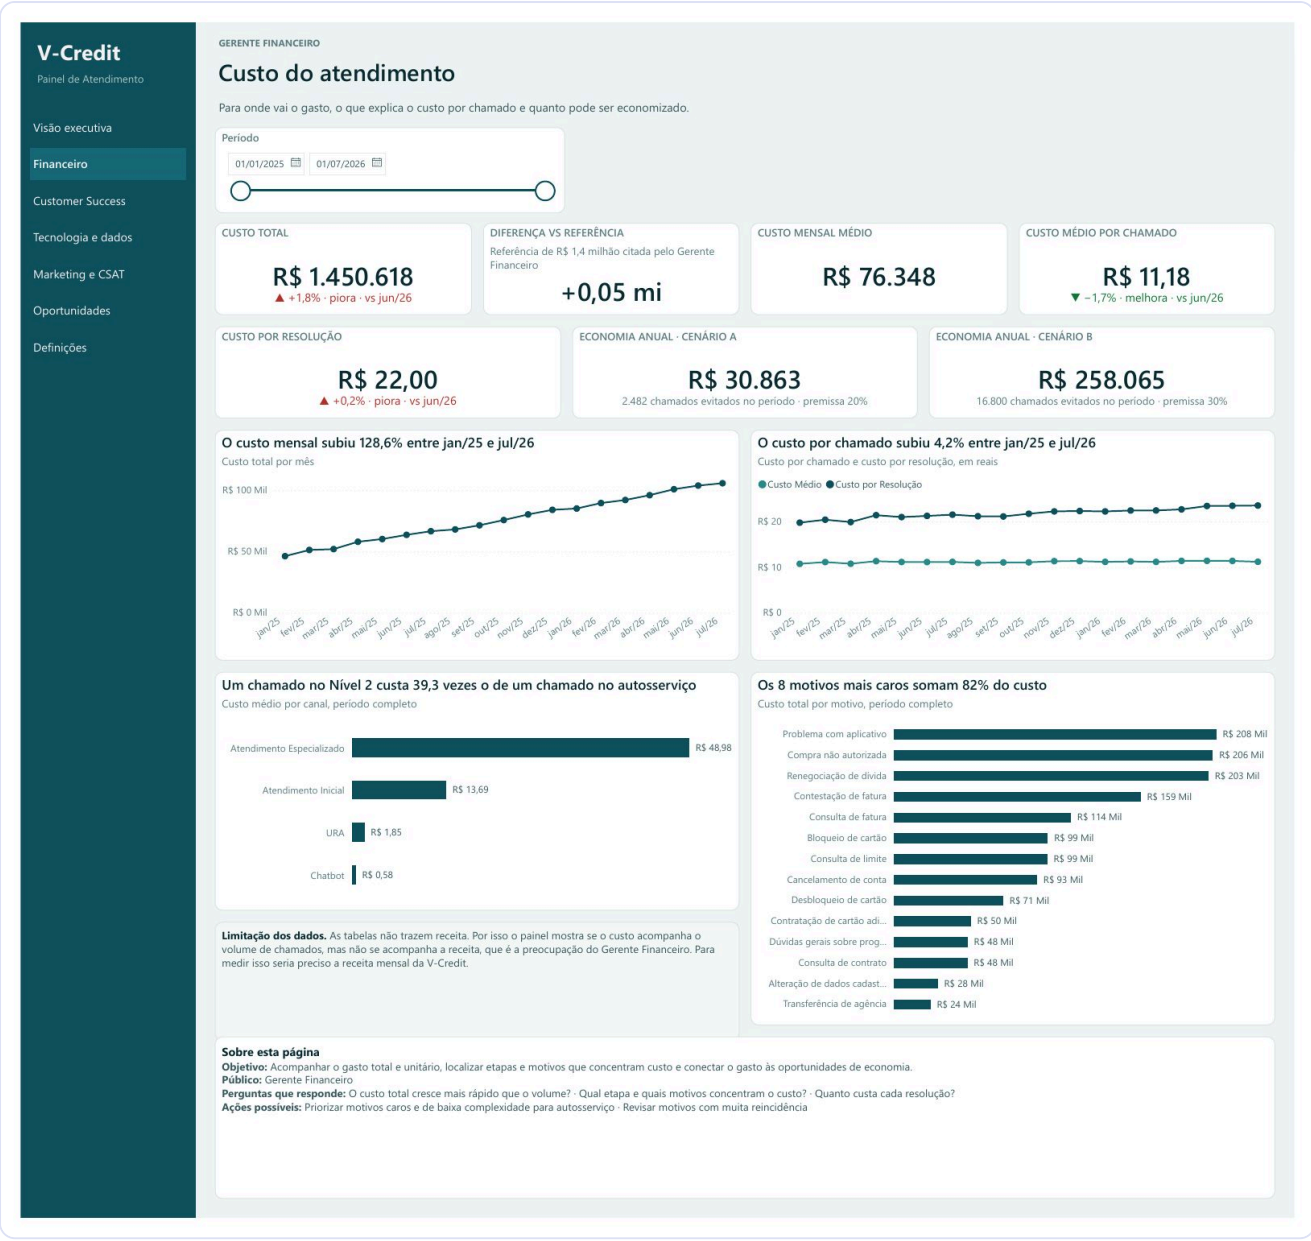


Figura 5. Painel, página 2: Financeiro (versão de 22/10/2026)



Figura 6. Painel, página 3: Customer Success (versão de 22/10/2026)

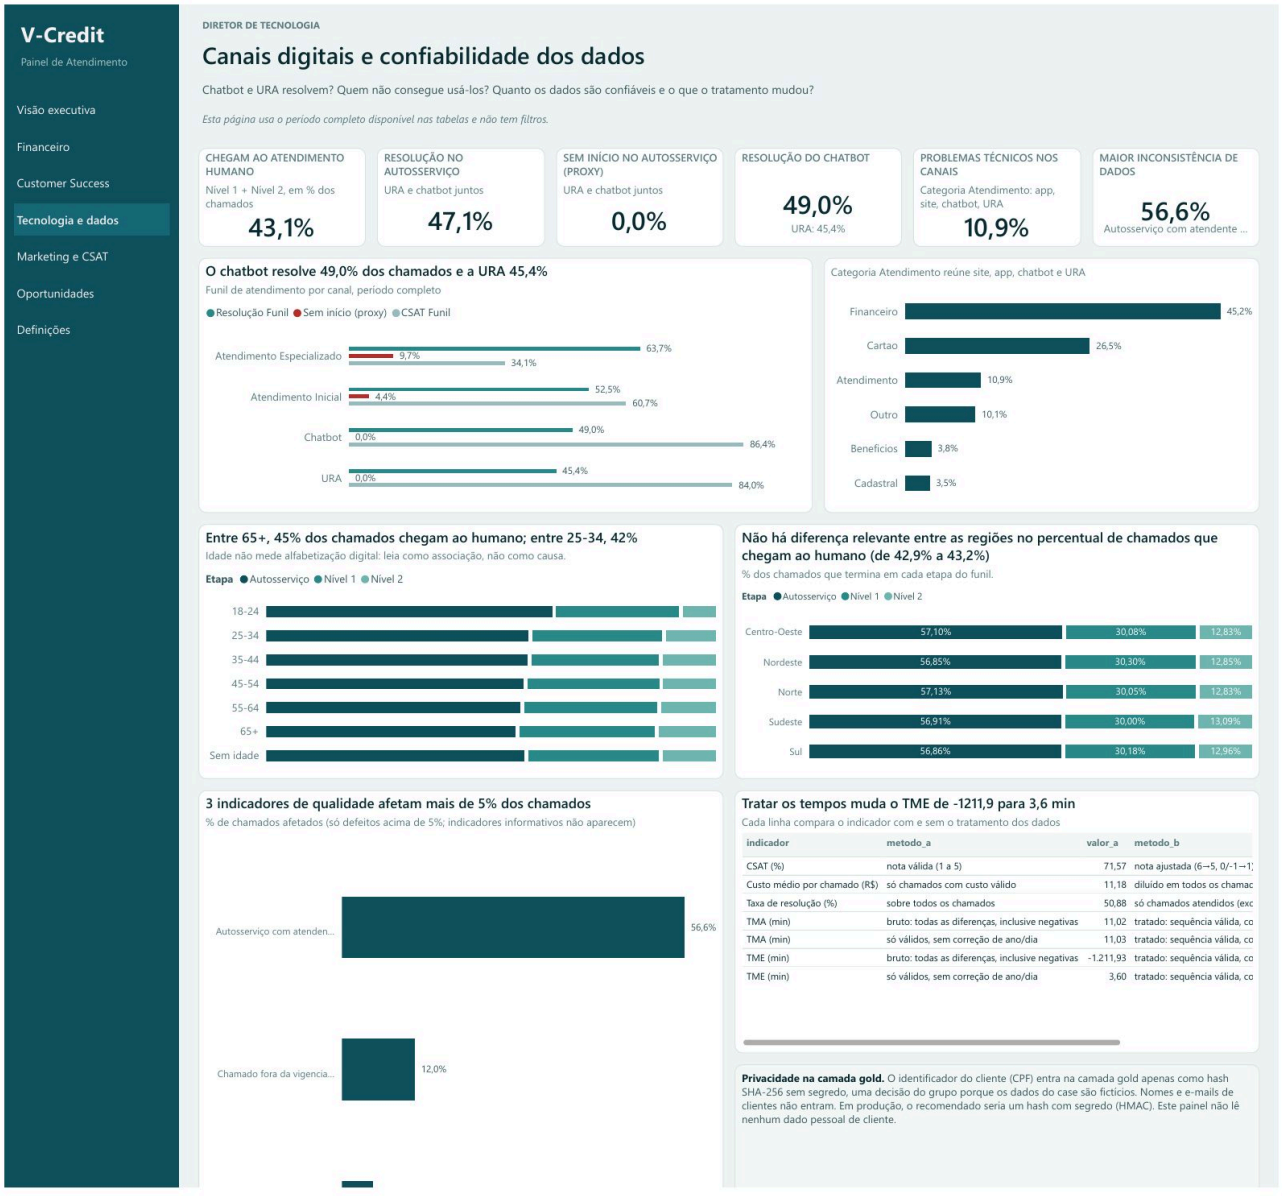


Figura 7. Painel, página 4: Tecnologia e dados (versão de 22/10/2026)

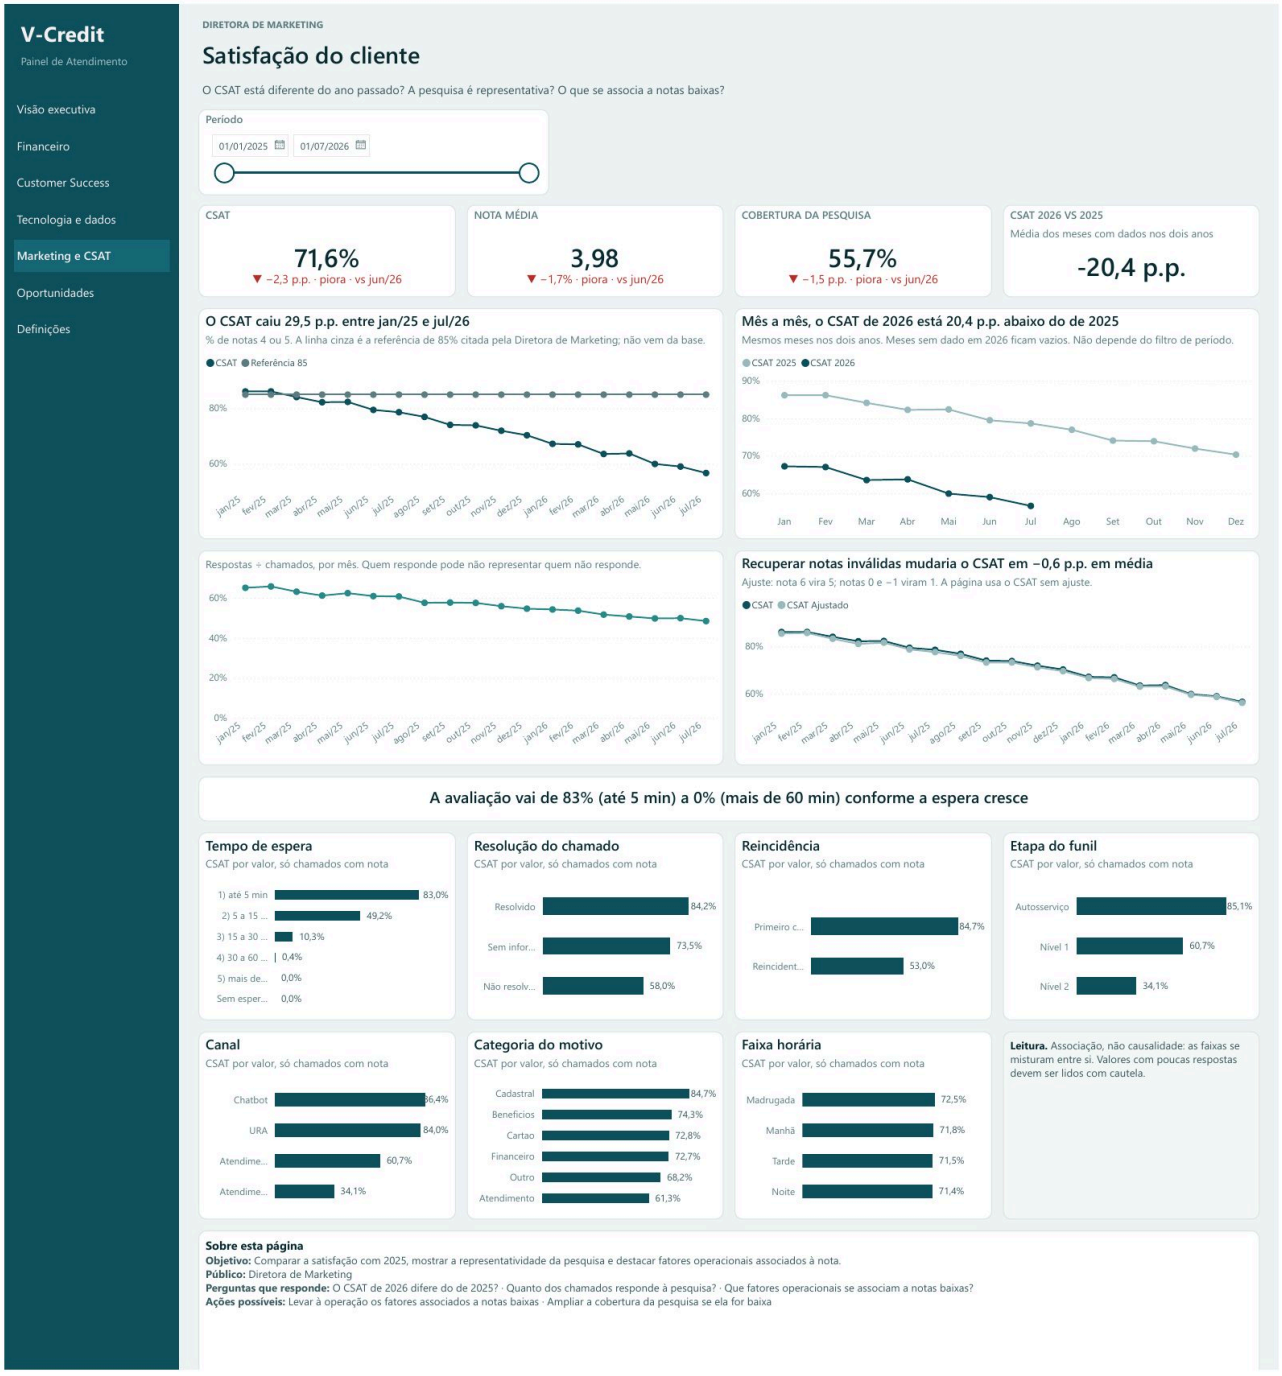


Figura 8. Painel, página 5: Marketing e CSAT (versão de 22/10/2026)

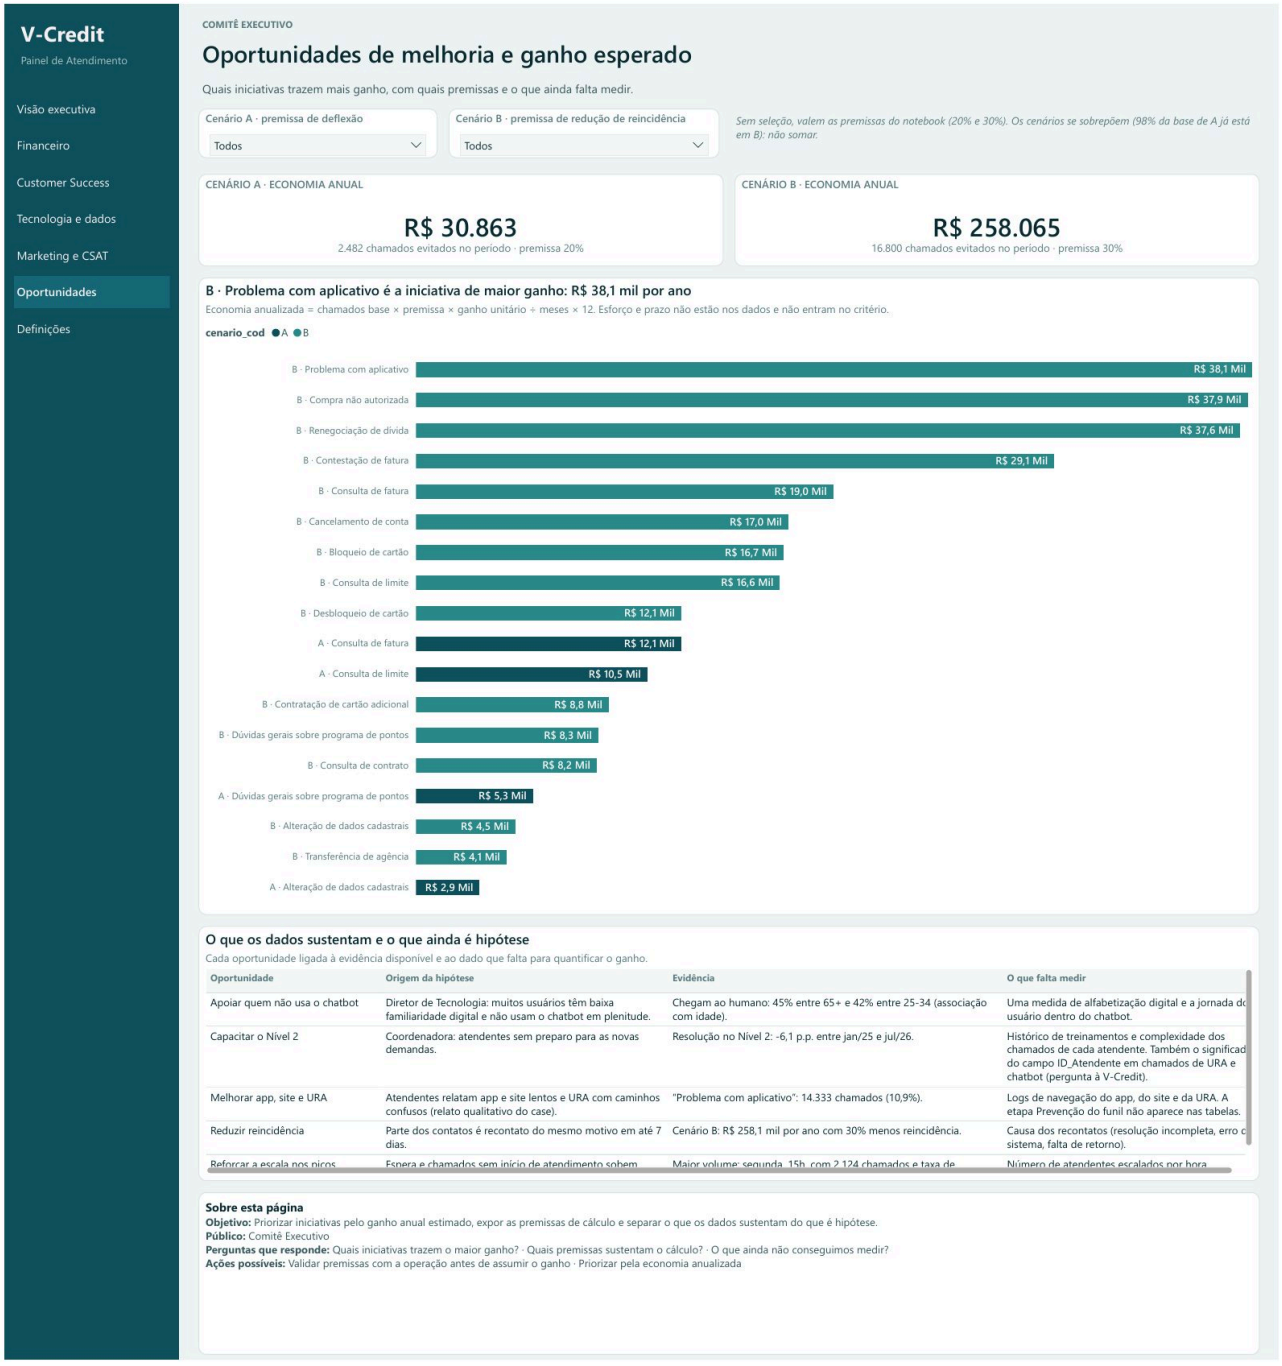


Figura 9. Painel, página 6: Oportunidades (versão de 22/10/2026)

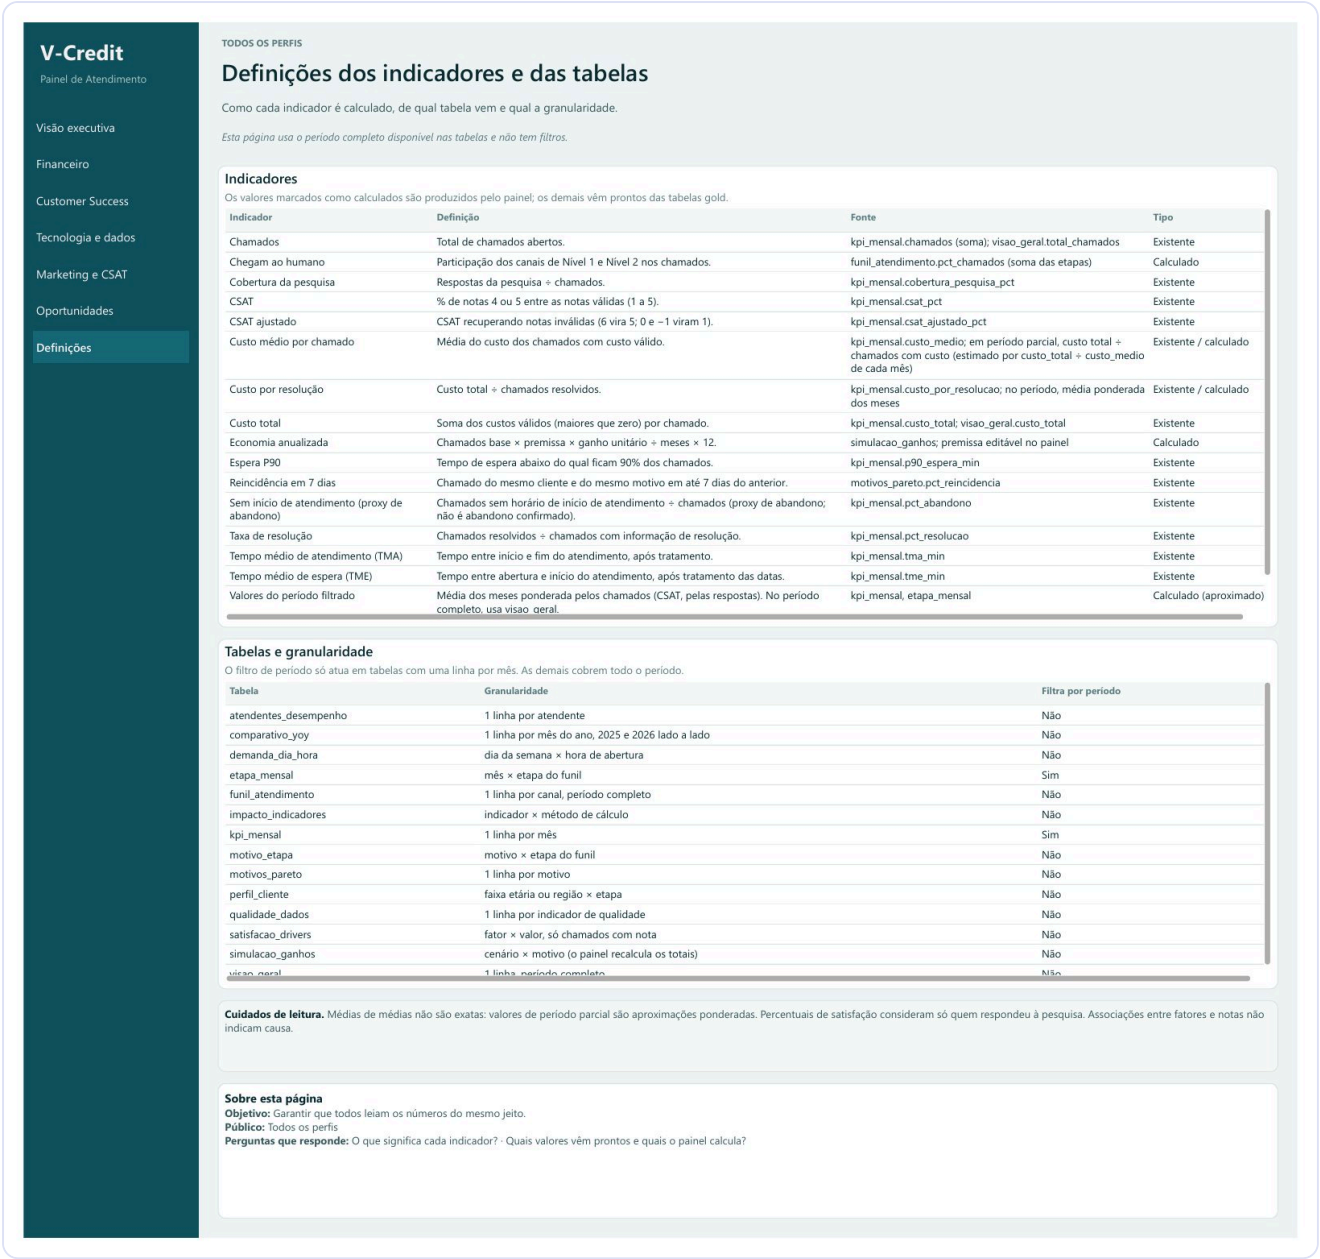


Figura 10. Painel, página 7: Definições (versão de 22/10/2026)

9 Anexo B — Evidências da idempotência

Provas de que o pipeline roda como Job e é idempotente. A leitura e a conclusão estão em `../notebooks-e-jobs.md` ; aqui ficam só os arquivos de origem.

Arquivo	O que é
`job-visagio.yaml`	Configuração real do Job `visagio - job` no Databricks Workflows (sem e-mail do criador)
`job-execucoes.png`	Print da lista de execuções do Job (7 execuções; 3 com gatilho "By scheduler"), cortado para não mostrar o e-mail do criador
`manifesto_rodada1_exp_20261022_012729.{csv,json}`	Manifesto original da exportação da rodada 1 (22/10 01:27 UTC, versão Delta da gold = 2), igual ao `_manifesto` do `pacote_powerbi.zip`
`manifesto_rodada2_exp_20261022_044507.{csv,json}`	Manifesto original da exportação da rodada 2 (22/10 04:45 UTC, versão Delta da gold = 7)
`comparacao_manifestos.csv`	Comparação original, feita pelo grupo, de linhas e `checksum_linhas` das 22 tabelas exportadas entre as duas rodadas (22 de 22 iguais)
`painel/painel-atendimento-v-credit.pdf`	PDF das 7 páginas do painel Power BI (22/10/2026), exportado do Desktop; sem metadados de autor. Mostra nomes de atendentes (mantidos por decisão do grupo; base fictícia)
`Validacao_Idempotencia.ipynb`	Foto de todas as tabelas `*_raw` , `*_silver` e `*_gold` (linhas e checksum `xxhash64`) e comparação linha a linha entre versões Delta. Versão limpa: sem `userName` nem `userId`

9.1 Cuidados

- Os manifestos só têm nome de tabela, contagens, checksums e horários; **não há dado pessoal**. Por isso o `.gitignore` abre uma exceção para os `.csv` desta pasta (`!docs/tecnico/evidencias/**/*.csv`).
- Antes de versionar qualquer print ou saída nova, confira se não mostra e-mail de usuário, CPF, nome ou e-mail de cliente.
- Todos os arquivos de manifesto e de comparação são os **originais** enviados pelo grupo, sem edição (os `.csv` mantêm o fim de linha CRLF de origem).