Camada Gold da V-Credit

Guia das células do notebook gold_atendimento: o que cada uma faz, o que cada linha representa e o que vale conferir antes de usar os números.

Este guia segue a ordem do notebook. Para cada célula ele explica a consulta ou a transformação, diz o que uma linha da tabela gerada representa, descreve as colunas e aponta os cuidados de interpretação. O modelo é uma estrela: uma fato no grão de chamado, sete dimensões, uma tabela de qualidade e 14 tabelas analíticas que respondem às perguntas do case (custo, satisfação, funil e dados).

Como o notebook está organizado

- **Preparação.** Células: Configuração, Funções auxiliares, Leitura de chamados, Leitura de tempos, custos e pesquisa. O que produz: Nada é gravado. Define nomes e parâmetros e carrega as Silvers em memória
- **Dimensões.** Células: dim_calendario, dim_hora, dim_faixa_espera, dim_canal, dim_motivo, dim_atendente, dim_cliente. O que produz: Sete tabelas descritivas. dim_cliente só é criada se clientes_silver tiver id_cliente (hoje tem)
- **Fato e qualidade.** Células: Montagem da fato e da tabela de qualidade; Gravação da fato e da qualidade. O que produz: fato_atendimento_gold e qualidade_chamado_gold, ambas com uma linha por chamado
- **Verificações.** Células: Integridade referencial e chaves únicas; Chamados nos membros desconhecidos; Valores sem correspondência. O que produz: Só leitura. A primeira interrompe a execução se encontrar chave órfã ou duplicada
- **Tabelas analíticas.** Células: visao_geral até simulacao_ganhos (14 células). O que produz: Tabelas agregadas, prontas para o BI ou para o material executivo
- **Fechamento.** Células: Resumo das tabelas Gold. O que produz: Imprime a contagem de linhas de cada tabela

Regras que valem para o notebook inteiro

- **Idempotente.** Toda tabela é recriada por inteiro (overwrite ou CREATE OR REPLACE) e nenhuma usa a hora do processamento. Rodar duas vezes dá o mesmo resultado.
- **Unidades.** A fato guarda tempos em segundos. As tabelas analíticas mostram minutos (`tme_min`, `tma_min`) e percentuais de 0 a 100 com duas casas.
- **Nulos ficam de fora da média.** AVG ignora nulos. Por isso o CSAT é calculado só entre quem respondeu a pesquisa e o TME só entre chamados com espera válida.
- **Nenhum chamado se perde.** Todos os joins para montar a fato são LEFT; o que não casa vira um membro desconhecido (chave negativa), nunca uma linha descartada.
- **Privacidade.** O id do cliente entra na Gold apenas como hash SHA-256 (`sha2` puro, sem segredo). Decisão do grupo: o `id_cliente` do case é dado fictício, não é CPF real de ninguém, então não há o risco de reversão que justificaria um HMAC. O nome do atendente não é dado restrito pelo projeto (ver dim_atendente).

Glossário dos indicadores

- **TME**: Tempo médio de espera: média de `tempo_espera_seg`, em minutos (abertura até início do atendimento).
- **TMA**: Tempo médio de atendimento: média de `tempo_atendimento_seg`, em minutos (início até fim).
- **P90 da espera**: Percentil 90 aproximado. Nove em cada dez chamados esperaram menos do que esse valor; mostra a cauda que a média esconde.
- **Abandono**: Chamado sem horário de início do atendimento. `pct_abandono` é a média da flag `abandonado`.
- **Resolução**: Média da flag `resolvido`. Chamados com valor inválido ou ausente ficam fora da conta.
- **CSAT**: Percentual de notas maiores ou iguais a 4 (`NOTA_SATISFEITO_MIN`), entre os chamados que têm nota.
- **CSAT ajustado**: Mesmo cálculo usando `nota_ajustada` (6 vira 5; 0 e -1 viram 1).
- **Custo por resolução**: Custo total dividido pelo número de chamados resolvidos.
- **Reincidência (7d)**: O mesmo cliente abriu outro chamado com o mesmo motivo até 7 dias depois do anterior.

- **Etapa do funil**: Autosserviço (URA e Chatbot), Nível 1 (Atendimento Inicial), Nível 2 (Atendimento Especializado).
- **Pareto**: Motivos ordenados por volume, com o percentual acumulado, para achar os poucos que concentram a maior parte dos chamados.
- **Membro desconhecido**: Linha especial de uma dimensão com chave negativa (-1, -2, -3) que recebe os chamados sem informação ou sem correspondência.

Preparação

Configuração, funções de apoio e leitura das tabelas Silver. Nada é gravado nesta etapa.

Configuração

O que faz. Importa o PySpark e declara todas as constantes que o resto do notebook usa: onde as tabelas ficam, como se chamam e quais parâmetros de negócio valem. Não lê nem grava nada.

Constantes

- **`CATALOGO e SCHEMA`**: Local de todas as tabelas: `dados_vcredit.default`.
- **`DESTINO_* (9)`**: Tabelas Silver lidas: clientes, atendentes, motivos, canais, canais_depara, custos, pesquisa_satisfacao, chamados_hora e chamados.
- **`GOLD_DIM_*, GOLD_FATO, GOLD_QUALIDADE_CHAMADO (9)`**: Nomes das tabelas do modelo em estrela, todas com o sufixo `_gold`.
- **`GOLD_VISAO_GERAL até GOLD_SIMULACAO_GANHOS (14)`**: Nomes das tabelas analíticas.
- **`LIMITE_REINCIDENCIA_DIAS = 7`**: Janela da reincidência: novo chamado do mesmo cliente e motivo em até 7 dias.
- **`NOTA_SATISFEITO_MIN = 4`**: Nota mínima para o chamado contar como satisfeito.
- **`AMOSTRA_MIN_ATENDENTE = 30`**: Mínimo de chamados para um atendente entrar nas comparações de desempenho.
- **`PCT_DEFLEXAO = 0.20`**: Premissa do cenário A: 20% dos chamados de baixa criticidade que hoje chegam ao humano passariam a ser resolvidos no autosserviço.
- **`PCT_REDUCAO_REINCIDENCIA = 0.30`**: Premissa do cenário B: 30% dos chamados reincidentes seriam evitados.
- **`CUSTO_REFERENCIA_ENTREVISTA = 1.400.000,00`**: Gasto citado pelo Gerente Financeiro (R$ 1,4 milhão em 19 meses). Serve de comparação com o custo total medido.
- **`FAIXAS_ESPERA`**: Lista de cinco faixas: id, rótulo e limite superior em segundos. Alimenta a dimensão de faixas e a regra que classifica cada chamado.
- **`NOMES_MES e NOMES_DIA`**: Nomes em português usados no calendário.

Atenção

- As duas premissas (20% e 30%) são hipóteses, não dados. Elas precisam de justificativa ou de uma análise de sensibilidade no material executivo.

Funções auxiliares

O que faz. Define cinco funções que evitam repetição ao longo do notebook.

- **`limpar(c)`**: Remove espaços das pontas, junta espaços repetidos (inclusive o espaço não separável) e transforma texto vazio, `null`, `none` e `nan` em nulo de verdade.
- **`norm_key(c)`**: Cria uma chave de texto: minúsculas, sem acentos, `_` e `-` viram espaço e espaços repetidos são compactados. É a mesma função da Silver de chamados, então a chave do motivo calculada aqui casa com a `motivo_chave` dos chamados.

- **`com_desconhecidos(df, membros)`**: Acrescenta à dimensão as linhas de membro desconhecido. Só os valores informados são preenchidos; as demais colunas ficam nulas, respeitando o tipo de cada uma.
- **`gravar_gold(df, destino)`**: Grava o DataFrame como tabela Delta substituindo a anterior (`overwrite` com `overwriteSchema`) e imprime a contagem de linhas.
- **`criar_gold(destino, sql)`**: Executa `CREATE OR REPLACE TABLE destino AS <consulta>` e imprime a contagem. É o que todas as tabelas analíticas usam.

Leitura de chamados

O que faz. Lê `chamados_silver`, confere se as dez colunas necessárias existem e monta o DataFrame `ch`, que é a espinha dorsal da fato. Nenhuma tabela é gravada.

Cada linha representa

Um chamado.

O que é montado

- **`id_cliente_hash`**: SHA-256 (`sha2`) do `id_cliente`, sem segredo. O id original não sai da Silver.
- **`sem_id_cliente`**: marca os chamados sem identificação do cliente.
- **`id_atendente_num`**: o id do atendente convertido para número. Valor inválido vira nulo.
- Mantém `canal_chave`, `motivo_chave`, `status_atendente`, `resolvido` e as flags de qualidade da Silver. O nome `status_atendente` é mantido em `chamados_silver`; só a `base_silver` o renomeia para `status_id_atendente`, e a Gold lê `chamados_silver`.

Validações

A célula lança erro se a Silver estiver vazia, se houver `id_chamado` nulo ou se houver `id_chamado` repetido. O total (`n_chamados`) fica guardado e é usado depois para provar que a fato tem exatamente uma linha por chamado.

Leitura de tempos, custos e pesquisa

O que faz. Prepara em memória as três fontes que complementam o chamado.

- **`hr`**. Fonte e conteúdo: `chamados_hora_silver`. Horários tratados (`abertura_ts`, `inicio_ts`, `fim_ts`) e os originais, tempos em segundos, `abandonado`, data e hora de abertura e as flags de correção e de erro de leitura. Acrescenta `tem_registro_hora = True`. Cada linha representa: Um chamado
- **`cu`**. Fonte e conteúdo: `custos_silver` agrupada por chamado. `custo` é a soma só dos lançamentos maiores que zero; `qtd_registros_custo` conta os lançamentos; `custo_com_problema` indica algum lançamento nulo ou menor ou igual a zero. Cada linha representa: Um chamado (vários lançamentos viram uma linha)
- **`ps`**. Fonte e conteúdo: `pesquisa_satisfacao_silver`. `nota`, `nota_ajustada`, `dq_nota_invalida` e `tem_pesquisa = True`. Cada linha representa: Um chamado com pesquisa

Atenção

- As colunas constantes `tem_registro_hora` e `tem_pesquisa` existem para distinguir, depois do join, "não há registro" (nulo, que vira falso) de "há registro".
- Chamado sem nenhum lançamento positivo fica com custo nulo, não zero. Chamados com mais de um custo têm os valores somados.

Dimensões

Sete tabelas que descrevem quando, onde, por que e quem. Cada uma tem uma chave inteira e um ou mais membros desconhecidos (a `dim_cliente` usa um hash como chave).

dim_calendario

Tabela gerada: dim_calendario_gold

O que faz. Lê o menor e o maior `data_abertura` dos tempos, estende o intervalo de 1º de janeiro do primeiro ano a 31 de dezembro do último e gera um registro para cada dia, mesmo os sem chamado. Assim o calendário nunca tem buracos.

Cada linha representa

Um dia. Para a base do case (jan/2025 a jul/2026) são 730 dias mais o membro desconhecido, 731 linhas.

- **`id_data`**: Chave inteira no formato aaaammdd (20250317).
- **`data`**: A data em si.
- **`ano, semestre, trimestre, mes, dia`**: Partes da data. Semestre é 1 ou 2.
- **`nome_mes, nome_dia`**: Nomes em português (Março, Segunda).
- **`ano_mes`**: Texto aaaa-mm. Ordena cronologicamente e é o eixo dos indicadores mensais.
- **`dia_semana`**: Número de 1 (domingo) a 7 (sábado), a convenção do Spark.
- **`fim_de_semana`**: Verdadeiro para sábado e domingo.

Membro desconhecido: `id_data = -1`, com `nome_mes` e `nome_dia` iguais a "Sem data" e o resto nulo. Recebe os chamados sem data de abertura válida.

dim_hora

Tabela gerada: dim_hora_gold

O que faz. Gera as 24 horas do dia.

Cada linha representa

Uma hora do dia (25 linhas com o desconhecido).

- **`id_hora`**: Hora de 0 a 23.
- **`rotulo_hora`**: Texto 00h, 01h, ..., 23h.
- **`faixa_horaria`**: Madrugada (0h a 5h), Manhã (6h a 11h), Tarde (12h a 17h), Noite (18h a 23h).
- **`ordem_faixa`**: 1 a 4 na ordem do dia. Existe para ordenar as faixas cronologicamente; ordenar o texto daria Madrugada, Manhã, Noite, Tarde.

Membro desconhecido: `id_hora = -1`, "Sem hora", `ordem_faixa = 5` (fica por último).

dim_faixa_espera

Tabela gerada: dim_faixa_espera_gold

O que faz. Cria a dimensão a partir da constante `FAIXAS_ESPERA`. É a mesma lista usada para classificar cada chamado na fato, então dimensão e fato nunca divergem.

Cada linha representa

Uma faixa de tempo de espera (6 linhas com o desconhecido).

- **`1.`** `rotulo_faixa`: 1) até 5 min. `limite_superior_seg`: 300
- **`2.`** `rotulo_faixa`: 2) 5 a 15 min. `limite_superior_seg`: 900
- **`3.`** `rotulo_faixa`: 3) 15 a 30 min. `limite_superior_seg`: 1800
- **`4.`** `rotulo_faixa`: 4) 30 a 60 min. `limite_superior_seg`: 3600
- **`5.`** `rotulo_faixa`: 5) mais de 60 min. `limite_superior_seg`: nulo (sem limite)
- **`-1.`** `rotulo_faixa`: Sem espera válida. `limite_superior_seg`: nulo

Os limites são inclusivos: uma espera de exatamente 5 minutos cai na faixa 1.

dim_canal

Tabela gerada: dim_canal_gold

O que faz. Lê `canais_silver` e acrescenta a coluna `etapa_funil`, deduzida do nome do canal.

Cada linha representa

Um canal de atendimento.

- **`id_canal, nome_canal`**: Identificador e nome padronizado (URA, CHATBOT, ATENDIMENTO INICIAL, ATENDIMENTO ESPECIALIZADO).
- **`tipo_canal, status_canal, is_ativo`**: Classificação (Autosserviço ou Humano), situação e flag de ativo, como vêm da Silver.
- **`etapa_funil`**: URA e CHATBOT viram Autosserviço; ATENDIMENTO INICIAL vira Nível 1; ATENDIMENTO ESPECIALIZADO vira Nível 2; qualquer outro vira "Não mapeado".

Membro desconhecido: `id_canal = -1`, com nome, tipo e etapa "Não mapeado". A coluna `_treatment_ts` da Silver não é levada para a Gold para manter a tabela idempotente.

Atenção

- `etapa_funil` sustenta o funil inteiro (funil, etapa mensal, motivos). Um canal novo que não esteja na regra cai em "Não mapeado" até ser incluído.
- A etapa Prevenção (site e app) do funil do case não aparece, porque a base de canais só traz os quatro canais de atendimento.

dim_motivo

Tabela gerada: dim_motivo_gold

O que faz. Lê `motivos_silver`, converte o id para número e calcula `motivo_chave` com `norm_key(nome_motivo)`. Descarta linhas sem id ou sem chave. Se dois ids tiverem a mesma chave, fica o de menor id. Depois confere que nenhum `id_motivo` se repete e lança erro se houver.

Cada linha representa

Um motivo de chamado.

- **`id_motivo`**: Chave numérica do motivo.
- **`nome_motivo, categoria`**: Nome e agrupamento do motivo.
- **`criticidade`**: Grau de criticidade em minúsculas (por exemplo `baixa`). O cenário A da simulação usa os de criticidade baixa.
- **`motivo_chave`**: Chave de texto normalizada, a mesma que o chamado carrega. É por ela que o chamado encontra o motivo.

Membro desconhecido: `id_motivo = -1`, "Não mapeado", criticidade "não mapeado".

dim_atendente

Tabela gerada: dim_atendente_gold

O que faz. Lê `atendentes_silver`, converte o id para número e, se um atendente aparecer mais de uma vez, mantém o de admissão mais recente (em empate, o de menor nível).

Cada linha representa

Um atendente cadastrado, mais três membros desconhecidos.

- **`id_atendente`**: Chave numérica.
- **`rotulo_atendente`**: Nome do atendente. Se o nome estiver vazio, usa "Atendente" seguido do id.
- **`nivel_atendimento`**: 1 ou 2.
- **`data_admissao, data_desligamento`**: Vigência do vínculo. O desligamento fica nulo para quem segue ativo.

- **`status_atendente, is_ativo`**: Situação (do cadastro) e flag derivada (ativo).

Membros desconhecidos

- **`-1`**. Rótulo: Sem atendente informado. Quando é usado: O chamado não trouxe atendente (comum no autosserviço)
- **`-2`**. Rótulo: Atendente inválido na origem. Quando é usado: O id veio, mas era inválido (0, 99, 999 ou texto)
- **`-3`**. Rótulo: Atendente fora do cadastro. Quando é usado: O id é válido, mas não existe na base de atendentes

Atenção

- O nome do atendente não é dado restrito pelo projeto: a regra de dado pessoal vale para CPF, nome e e-mail de clientes. Está em aberto, e vale só para o material do Comitê Executivo, se o rótulo mostra o nome real ou um rótulo anônimo como "Atendente 4". Para o uso interno, o nome aparece normalmente.

dim_cliente (condicional)

Tabela gerada: dim_cliente_gold

O que faz. Só roda se `clientes_silver` tiver a coluna `id_cliente`. Hoje ela tem, então a tabela é criada, com uma linha por cliente identificado apenas pelo hash. Se a coluna faltasse, a célula apagaria a tabela (se existir), marcaria `DIM_CLIENTE_CRIADA = False` e imprimiria um aviso; a célula que gera `perfil_cliente` usa essa marca. A Silver entrega `idade`, `data_cadastro` (`yyyy/MM/dd`) e `dia_vencimento_fatura` como texto, então a Gold converte: `idade` com `cast` para inteiro, `dia_vencimento_fatura` com `try_cast` para inteiro e `data_cadastro` com `to_date(data_cadastro, 'yyyy/MM/dd')`. A `regiao` já vem em maiúsculas.

Cada linha representa

Um cliente (o cadastro mais antigo, se houver duplicidade). Na Silver são 47.705 clientes.

- **`id_cliente_hash`**: SHA-256 do id do cliente após limpar. É a chave.
- **`faixa_etaria`**: Sem idade, 18-24, 25-34, 35-44, 45-54, 55-64 ou 65+. Idade fora de 18 a 110 já vira nula na Silver e cai em "Sem idade", então não há menores de 18 na faixa 18-24.
- **`regiao`**: Região do cliente; nulo vira "Sem região".
- **`dia_vencimento_fatura, data_cadastro`**: Dia de vencimento (inteiro) e data de abertura do cadastro (date). Valor nulo ou impossível de converter vira nulo, sem quebrar a execução.

Nome, e-mail, idade exata e id original não são levados para a Gold.

Membro desconhecido: o notebook atual não cria nenhum. Na fato, a chave do cliente fica nula quando o chamado não tem `id_cliente`. Já os 1.330 chamados (1,0%) que trazem `id_cliente`, mas com id inexistente em `clientes_silver` (flag `dq_cliente_sem_correspondencia`), recebem um hash que não casa com nenhuma linha da dimensão e ficam fora de `perfil_cliente` (join interno). Proposta ainda não implementada: criar um membro `SEM_CADASTRO`, com hash fixo, para recebê-los.

Atenção

- A tabela passa a ser criada: `clientes_silver` já traz `id_cliente`. O aviso antigo ("hoje não é criada") deixa de valer, embora a condição continue no código.
- O membro `SEM_CADASTRO` é uma proposta ainda não decidida. Enquanto não existir, os 1.330 chamados sem cliente na Silver ficam fora de `perfil_cliente`.

Fato e qualidade

Onde as fontes se encontram. Cada chamado vira uma linha na fato e uma linha na tabela de qualidade.

Montagem da fato e da tabela de qualidade

O que faz. Junta o chamado com tempos, custos, pesquisa e dimensões, calcula as chaves e os indicadores por chamado e separa o resultado em duas tabelas: fato (22 colunas, o que se analisa) e qualidade (24 colunas, o que se audita). Nada é gravado nesta célula; ela só define os DataFrames.

Passo a passo

- **Tabelas de busca.** `lk_canal` liga cada `canal_chave` ao `id_canal` e à etapa do funil; `lk_motivo` liga `motivo_chave` ao `id_motivo`; `lk_atendente` traz nível, admissão e desligamento de cada atendente cadastrado.
- **Faixa de espera.** Uma expressão `CASE` percorre `FAIXAS_ESPERA`: espera nula dá -1; senão a primeira faixa cujo limite comporta a espera; acima do último limite, a faixa 5.
- **Junção.** Parte de `ch` e faz `LEFT JOIN` com hr, cu, ps e as três tabelas de busca. Os pequenos usam `broadcast`.
- **Preenchimento.** Flags e contagens nulas viram falso ou zero (`tem_registro_hora`, `tem_pesquisa`, `qtd_registros_custo` e outras).
- **Chaves substitutas.** `id_data`, `id_hora`, `id_canal`, `id_motivo`, `id_atendente` e `id_faixa_espera`, sempre com -1 quando não há correspondência.
- **Indicadores.** `satisfeito` e `satisfeito_ajustado`: nota maior ou igual a 4, nulo se não houver nota.
- **Flags de qualidade do atendente e reincidência, descritas abaixo.**

Regra do id_atendente

- Id válido e encontrado no cadastro: O próprio id.
- Id válido, mas ausente do cadastro: -3 (fora do cadastro).
- Id inválido na origem (`status_atendente = invalido_na_origem`): -2.
- Sem atendente informado: -1.

Flags de qualidade do atendente

- **`atendente_nao_encontrado`**: Há id válido, mas ele não existe no cadastro.
- **`atendente_fora_vigencia`**: O chamado foi aberto antes da admissão ou depois do desligamento do atendente.
- **`autosservico_com_atendente`**: O canal é de autosserviço, mas o chamado traz atendente. Em tese não deveria.
- **`atendente_nivel_diverge_canal`**: Atendente de nível 2 em canal Nível 1, ou o contrário.

Reincidência (reincidente_7d)

Os chamados são agrupados por cliente e motivo, ordenados pela abertura, e a função `lag` traz a abertura do chamado anterior do mesmo grupo. Se a diferença for de até 7 dias (`LIMITE_REINCIDENCIA_DIAS` × 86.400 segundos), o chamado é reincidente. O primeiro chamado do grupo, o chamado sem cliente e o chamado sem motivo são sempre falsos.

Fato_atendimento_gold: cada linha é um chamado (22 colunas)

- **`id_chamado`**: Identificador do chamado (chave primária).
- **`id_cliente_hash`**: Hash SHA-256 do cliente. Nulo se o chamado não tem cliente.
- **`id_data`**: Dia da abertura (aaaammdd). -1 se não há data.
- **`id_hora`**: Hora da abertura (0 a 23). -1 se não há hora.
- **`id_canal`**: Canal. -1 se não mapeado.
- **`id_motivo`**: Motivo. -1 se não mapeado.
- **`id_atendente`**: Atendente. -1, -2 ou -3 conforme a regra acima.
- **`id_faixa_espera`**: Faixa do tempo de espera. -1 se a espera não é válida.

- **`abertura_ts, inicio_ts, fim_ts`**: Instantes de abertura, início e fim do atendimento, já com as correções de ano e de virada de dia.
- **`tempo_espera_seg, tempo_atendimento_seg, tempo_total_seg`**: Durações em segundos. Ficam nulas quando a sequência de horários é incoerente.
- **`custo`**: Soma dos lançamentos de custo positivos, em reais.
- **`nota, nota_ajustada`**: Nota válida de 1 a 5 e nota após o ajuste de cenário.
- **`resolvido`**: Verdadeiro, falso ou nulo (não informado ou inválido).
- **`abandonado`**: Verdadeiro quando não há horário de início do atendimento.
- **`reincidente_7d`**: Verdadeiro quando é reincidência do mesmo cliente e motivo em até 7 dias.
- **`satisfeito, satisfeito_ajustado`**: Nota (ou nota ajustada) maior ou igual a 4. Nulo sem nota.

Qualidade_chamado_gold: cada linha é um chamado (24 colunas)

- **`id_chamado`**: Liga a tabela à fato (1 para 1).
- **`abertura_erro_parse, inicio_erro_parse, fim_erro_parse`**: O horário veio preenchido, mas não pôde ser lido como data.
- **`ano_abertura_corrigido, dia_fim_corrigido`**: Houve correção do ano de abertura (virada dezembro e janeiro) ou do dia do fim (virada da meia-noite).
- **`abertura_original_ts, fim_original_ts`**: Horários antes das correções. Servem para medir o impacto do tratamento.
- **`canal_mapeado, motivo_mapeado`**: O canal e o motivo do chamado foram encontrados nas dimensões.
- **`tem_registro_hora, tem_pesquisa`**: Existe registro na base de horários e na de pesquisa.
- **`sem_id_cliente`**: O chamado não traz id de cliente.
- **`qtd_registros_custo, custo_com_problema`**: Quantos lançamentos de custo o chamado tem e se algum é nulo ou não positivo.
- **`dq_nota_invalida`**: A nota veio fora de 1 a 5.
- **`dq_resolvido_invalido, dq_resolvido_ausente`**: O campo resolvido veio com valor inválido ou em branco.
- **`dq_atendente_invalido, status_atendente`**: Problema com o id do atendente na origem e a classificação dele.
- **`atendente_nao_encontrado, atendente_fora_vigencia, autosservico_com_atendente, atendente_nivel_diverge_canal`**: As quatro flags do atendente descritas acima.

Atenção

- A reincidência olha apenas o chamado imediatamente anterior do mesmo cliente e motivo, e exige id de cliente. Chamados sem cliente nunca são reincidentes, o que tende a subestimar a taxa.
- As colunas de qualidade ficam fora da fato de propósito: a fato fica enxuta e a auditoria continua acessível pela chave `id_chamado`.

Gravação da fato e da qualidade

O que faz. Grava `fato_atendimento_gold` e `qualidade_chamado_gold` e confere se a fato tem tantas linhas quanto chamados lidos na Silver (`n_chamados`).

Cada linha representa

Um chamado, nas duas tabelas.

Atenção

- A conferência `n_fato == n_chamados` é o teste que garante que os joins não duplicaram nem perderam chamados. Se falhar, a causa mais provável é uma dimensão ou tabela de busca com chave repetida.

Verificações

Consultas de conferência. Só leem as tabelas já gravadas.

Integridade referencial e chaves únicas

O que faz. Para cada uma das seis chaves estrangeiras da fato, procura chamados cuja chave não existe na dimensão (órfãos) e, em seguida, procura chaves repetidas em cada dimensão. Se qualquer contagem for diferente de zero, a execução para com erro. Se tudo estiver certo, exibe as duas tabelas de resultado.

Cada linha representa

- **Órfãos.** Linha representa: Uma chave estrangeira da fato. Colunas: `chave`, `chamados_sem_dimensao`
- **Duplicadas.** Linha representa: Uma dimensão. Colunas: `dimensao`, `chaves_duplicadas`

São seis linhas em cada uma: data, hora, faixa de espera, canal, motivo e atendente. O esperado é zero em tudo; como os membros desconhecidos absorvem o que não casa, a ausência de órfãos é um resultado exigido, não uma sorte.

Atenção

- `dim_cliente` não entra, porque a chave de cliente da fato pode ser nula e a dimensão pode nem existir. Atenção: os 1.330 chamados com id sem cadastro também não aparecem como órfãos aqui. Se o membro `SEM_CADASTRO` for criado, vale incluir a `dim_cliente` (ignorando chaves nulas); sem ele, a checagem pararia a execução por causa desses 1.330.

Chamados nos membros desconhecidos

O que faz. Conta quantos chamados caíram em cada membro desconhecido, para medir o quanto de informação está faltando.

Cada linha representa

Uma dimensão (o atendente aparece dividido em três linhas, uma para cada membro desconhecido).

- **`dimensao`**: canal, motivo, data, hora, faixa_espera ou os três tipos de atendente.
- **`chamados_desconhecidos`**: Chamados com a chave negativa daquela dimensão.
- **`total`**: Total de chamados da fato, para calcular o percentual.

Não é um teste de passa ou falha. Números altos indicam problema de dado na origem. Atendente sem informação (-1) é esperado no autosserviço.

Valores sem correspondência

O que faz. Lista os textos de motivo e de canal que o chamado trouxe e que não foram encontrados nas dimensões, com a quantidade de chamados de cada um. Mostra no máximo 30, dos mais frequentes para os menos.

Cada linha representa

Um valor distinto sem correspondência (já normalizado).

- **`campo`**: motivo ou canal.
- **`valor`**: A chave de texto que não casou.
- **`count`**: Quantos chamados trazem esse valor.

Atenção

- Se algo aparecer aqui, o caminho é incluir a variação no mapa de apelidos de canais ou corrigir a Silver de motivos. Esta célula usa o DataFrame `base` criado antes, então só funciona na mesma sessão da montagem da fato.

Tabelas analíticas

Catorze tabelas agregadas, todas calculadas a partir da fato, das dimensões e da qualidade. Cada uma responde a uma pergunta do case.

visao_geral

Tabela gerada: visao_geral_gold

Pergunta que responde

Qual é a fotografia geral da operação no período e o custo medido bate com o R$ 1,4 milhão citado na entrevista?

Fontes. fato junto com o calendário (JOIN). Como o calendário tem o membro -1, nenhum chamado sai da conta.

Cada linha representa

O período inteiro. A tabela tem uma única linha.

- **`total_chamados`**: Número de chamados.
- **`primeira_data, ultima_data, meses_no_periodo`**: Intervalo coberto e quantidade de meses distintos.
- **`abandonados, pct_abandono`**: Chamados sem início de atendimento, em quantidade e em %.
- **`pct_resolucao`**: % de chamados resolvidos (entre os que têm a informação).
- **`tme_min, tma_min`**: Espera média e duração média do atendimento, em minutos.
- **`csat_pct, nota_media`**: % de notas ≥ 4 e média das notas, entre os respondentes.
- **`custo_total, custo_medio_chamado`**: Soma dos custos e custo médio entre chamados com custo.
- **`custo_mensal_medio`**: Custo total dividido pelo número de meses.
- **`custo_referencia_entrevista, diferenca_vs_referencia`**: O R$ 1,4 milhão da entrevista e a diferença entre o custo medido e ele.

Atenção

- A diferença para a referência serve de teste de coerência dos dados, não de meta. O R$ 1,4 milhão é uma fala de entrevista, em "mais de" e sobre 19 meses.

kpi_mensal

Tabela gerada: kpi_mensal_gold

Pergunta que responde

Como os indicadores evoluíram mês a mês? O custo cresce todo mês? O tempo de atendimento subiu e a resolução caiu? A satisfação piorou desde o começo de 2025?

Fontes. fato e calendário. Chamados sem data ficam de fora (`ano_mes` nulo).

Cada linha representa

Um mês (`ano_mes`). Para jan/2025 a jul/2026 são 19 linhas.

- **`chamados, abandonados, pct_abandono`**: Volume e abandono do mês.
- **`pct_resolucao`**: % de chamados resolvidos.
- **`tme_min, p90_espera_min`**: Espera média e percentil 90 da espera, em minutos.
- **`tma_min`**: Duração média do atendimento.
- **`custo_total, custo_medio`**: Gasto do mês e custo médio por chamado.
- **`custo_por_resolucao`**: Custo total dividido pelos chamados resolvidos.
- **`respostas_pesquisa, cobertura_pesquisa_pct`**: Quantos chamados têm nota e que % do mês isso representa.
- **`csat_pct, nota_media`**: Satisfação do mês, entre os respondentes.
- **`csat_ajustado_pct`**: CSAT usando a nota ajustada (recupera notas fora de 1 a 5).

Atenção

- Olhe `cobertura_pesquisa_pct` junto com o CSAT: um CSAT alto com cobertura baixa é pouco confiável.

comparativo_yoy

Tabela gerada: comparativo_yoy_gold

Pergunta que responde

A queda de satisfação é externa, como sugere a Diretora de Marketing, ou a operação piorou em relação ao mesmo mês do ano passado?

Fontes. fato e calendário, filtrados em 2025 e 2026. As colunas são geradas por uma função (`_yoy`) que repete a mesma expressão para cada ano.

Cada linha representa

Um mês do ano (de 1 a 12), com as colunas de 2025 e 2026 lado a lado.

- **`mes, nome_mes`**: Mês do ano.
- **`chamados_AAAA`**: Volume do mês naquele ano.
- **`csat_pct_AAAA, pct_abandono_AAAA, pct_resolucao_AAAA`**: Satisfação, abandono e resolução.
- **`tme_min_AAAA, custo_medio_AAAA`**: Espera média em minutos e custo médio por chamado.

Atenção

- Os dados vão até julho de 2026. Nos meses 8 a 12, as colunas de 2026 vêm com zero chamados e demais indicadores nulos. Compare apenas janeiro a julho.
- Os anos 2025 e 2026 estão fixos no código. Se o período mudar, ajuste a lista de anos.

funil_atendimento

Tabela gerada: funil_atendimento_gold

Pergunta que responde

Onde está o volume e onde está o custo? Quanto do atendimento ocorre em cada etapa e canal, e com que resultado?

Fontes. fato, dim_canal.

Cada linha representa

Um canal, agrupado por etapa do funil (4 canais mais, se houver, "Não mapeado"). Ordenada de Autosserviço para Nível 2.

- **`etapa_funil, canal, tipo_canal`**: Posição do canal no funil e sua classificação.
- **`chamados, pct_chamados`**: Volume e participação no total (função de janela sobre todas as linhas).
- **`abandonados, pct_abandono`**: Abandono no canal.
- **`pct_resolucao`**: % de chamados resolvidos.
- **`tme_min, tma_min`**: Espera média e duração média.
- **`custo_total, pct_custo`**: Custo do canal e participação no custo total.
- **`custo_medio, custo_por_resolucao`**: Custo por chamado e por chamado resolvido.
- **`csat_pct`**: Satisfação no canal.

Atenção

- Pelos dados, cada chamado tem um único canal. A tabela mostra o volume por canal, não a taxa de passagem de uma etapa para a outra: não dá para dizer quantos clientes saíram do chatbot e foram para o Nível 1.

etapa_mensal

Tabela gerada: etapa_mensal_gold

Pergunta que responde

Cada etapa do funil piorou ao longo do tempo? A queda da resolução no Nível 2, citada pela Coordenadora, aparece nos dados?

Fontes. fato, calendário e dim_canal. Sem data fica de fora.

Cada linha representa

Um mês em uma etapa do funil (aproximadamente 19 meses × 3 etapas).

- **`ano_mes, etapa_funil`**: Mês e etapa.
- **`chamados`**: Volume.
- **`pct_abandono, pct_resolucao`**: Abandono e resolução.
- **`tme_min, tma_min`**: Espera e duração médias.
- **`custo_medio, csat_pct`**: Custo por chamado e satisfação.

motivos_pareto

Tabela gerada: motivos_pareto_gold

Pergunta que responde

Quais motivos concentram a maior parte dos chamados e do custo, e quais chegam mais ao atendimento humano?

Fontes. fato, dim_motivo e dim_canal. Uma primeira consulta agrega por motivo; a segunda calcula os percentuais e o acumulado.

Cada linha representa

Um motivo de chamado, do mais frequente para o menos frequente.

- **`motivo, categoria, criticidade`**: Identificação do motivo.
- **`chamados, pct_chamados`**: Volume e participação no total.
- **`pct_acumulado`**: Soma corrida de `pct_chamados`. É a curva de Pareto: onde ela cruza 80%, termina o grupo dos motivos que mais pesam.
- **`pct_chegou_humano`**: % dos chamados do motivo que ocorreram em Nível 1 ou Nível 2.
- **`pct_nivel2`**: % que chegou ao Nível 2, a etapa mais cara.
- **`pct_resolucao, pct_reincidencia`**: Resolução e reincidência em 7 dias.
- **`tma_min`**: Duração média do atendimento.
- **`custo_total, custo_medio, pct_custo`**: Custo do motivo, por chamado e participação no custo total.
- **`csat_pct`**: Satisfação.

Atenção

- O motivo "Não mapeado" também aparece, se existir. Chamados em canal não mapeado não entram nas colunas por etapa.

motivo_etapa

Tabela gerada: motivo_etapa_gold

Pergunta que responde

Em que etapa cada motivo é atendido? Quais motivos poderiam ser resolvidos antes de chegar ao humano?

Fontes. fato, dim_motivo e dim_canal.

Cada linha representa

Um motivo em uma etapa do funil.

- **`categoria, motivo, etapa_funil`**: Identificação.
- **`chamados`**: Volume daquele motivo naquela etapa.
- **`pct_do_motivo`**: Participação da etapa dentro do motivo. As linhas de um mesmo motivo somam 100%.
- **`pct_resolucao, tma_min, custo_medio`**: Resolução, duração média e custo médio naquela combinação.

Serve para achar candidatos à deflexão: motivos simples, com boa resolução no autosserviço e custo bem menor ali do que no humano.

demanda_dia_hora

Tabela gerada: demanda_dia_hora_gold

Pergunta que responde

Em quais dias e horários a demanda e a espera são maiores? Onde falta capacidade?

Fontes. fato, calendário e dim_hora. Exclui chamados sem data ou sem hora.

Cada linha representa

Um dia da semana em uma hora de abertura. No máximo 7 × 24 = 168 linhas.

- **`dia_semana, nome_dia`**: 1 (domingo) a 7 (sábado) e o nome.
- **`hora_abertura, faixa_horaria`**: Hora (0 a 23) e período do dia.
- **`chamados`**: Total de chamados do período inteiro naquela combinação.
- **`pct_abandono`**: Abandono naquele horário.
- **`tme_min, p90_espera_min`**: Espera média e percentil 90, em minutos.

Atenção

- `chamados` é um total do período, não uma média por dia. Serve para comparar horários entre si, como em um mapa de calor.

atendentes_desempenho

Tabela gerada: atendentes_desempenho_gold

Pergunta que responde

Como cada atendente se compara aos colegas do mesmo nível em resolução e tempo? O desempenho tem relação com o tempo de casa?

Fontes. fato, dim_atendente, calendário e a tabela de qualidade. Só atendentes cadastrados (`id_atendente > 0`). Uma primeira consulta agrega por atendente; a segunda compara com a média do nível.

Cada linha representa

Um atendente cadastrado que tenha chamados, ordenado por nível e volume.

- **`id_atendente, rotulo_atendente`**: Identificação (o rótulo traz o nome).
- **`nivel_atendimento, data_admissao, data_desligamento`**: Nível e vigência do vínculo.
- **`chamados, atendimentos_validos`**: Total de chamados e quantos têm duração de atendimento válida.
- **`tma_min, p90_tma_min`**: Duração média e percentil 90, em minutos.
- **`pct_resolucao, csat_pct, custo_medio`**: Resolução, satisfação e custo médio.
- **`primeiro_chamado, ultimo_chamado`**: Primeira e última data em que atendeu.
- **`chamados_fora_vigencia`**: Chamados abertos antes da admissão ou depois do desligamento.
- **`amostra_suficiente`**: Verdadeiro se tem ao menos 30 chamados (`AMOSTRA_MIN_ATENDENTE`).

- **`tempo_casa_meses_no_ultimo_chamado`**: Meses entre a admissão e o último chamado (ou o desligamento, se anterior).
- **`pct_resolucao_vs_media_nivel`**: Diferença para a média do nível, em pontos percentuais. Positivo é melhor que a média.
- **`tma_vs_media_nivel`**: Diferença do TMA para a média do nível, em minutos. Positivo é mais lento que a média.
- **`rank_resolucao_no_nivel`**: Posição por resolução dentro do nível, separando atendentes com e sem amostra suficiente.

Atenção

- As médias de comparação usam só atendentes com amostra suficiente. Quem tem poucos chamados aparece, mas não distorce a referência.
- `chamados_fora_vigencia` diferente de zero indica dado inconsistente (atendimento atribuído a quem não estava no quadro).
- A tabela traz o nome do atendente, que não é dado restrito. Para o material do Comitê Executivo, a escolha entre o nome e um rótulo como "Atendente <id>" continua em aberto (ver dim_atendente).

satisfacao_drivers

Tabela gerada: satisfacao_drivers_gold

Pergunta que responde

O que está associado a uma nota melhor ou pior: tempo de espera, etapa, canal, motivo, resolução, reincidência ou horário?

Fontes. fato, faixa de espera, canal, motivo e hora, só chamados com nota. A consulta é a união (UNION ALL) de sete agrupamentos gerados por um laço em Python.

Cada linha representa

Um valor de uma dimensão de análise (formato longo). Por exemplo: faixa_espera = "5) mais de 60 min".

- **`dimensao`**: faixa_espera, etapa_funil, canal, categoria_motivo, resolucao, reincidencia ou faixa_horaria.
- **`valor`**: O valor daquela dimensão (por exemplo Resolvido, Reincidente (7d), Noite).
- **`respostas`**: Número de pesquisas respondidas nesse valor.
- **`csat_pct, nota_media`**: % de notas ≥ 4 e nota média.

Atenção

- É associação, não causa. Compare valores dentro da mesma dimensão e observe respostas antes de concluir.
- O formato longo facilita um único gráfico de barras com filtro por dimensão no BI.

perfil_cliente (condicional)

Tabela gerada: perfil_cliente_gold

Pergunta que responde

O perfil do cliente explica o baixo uso do chatbot? A hipótese do Diretor de Tecnologia é que muitos usuários são analfabetos digitais. Clientes mais velhos ou de certas regiões usam menos o autosserviço, abandonam mais ou ficam menos satisfeitos?

Fontes. fato, dim_canal e dim_cliente (join interno pelo hash do cliente). Só roda se `dim_cliente` existir (hoje existe); senão apaga a tabela e avisa.

Cada linha representa

Um valor de faixa etária ou de região em uma etapa do funil.

- **`dimensao, valor`**: faixa_etaria ou regiao, e o valor correspondente.
- **`etapa_funil`**: Etapa do funil.
- **`chamados`**: Volume.
- **`pct_da_dimensao`**: Participação da etapa dentro daquele valor. Soma 100% por valor. Permite ver, por exemplo, que % dos clientes de 65+ ficam no autosserviço.
- **`pct_resolucao, pct_abandono, csat_pct, custo_medio`**: Indicadores da combinação.

Atenção

- Chamados sem cliente identificado ficam fora (join interno). Isso inclui os 1.330 chamados (1,0%) cujo `id_cliente` não existe em `clientes_silver`, a menos que o membro `SEM_CADASTRO` seja criado.
- A idade é só um indicador indireto de familiaridade digital. A conclusão precisa dessa ressalva.

qualidade_dados

Tabela gerada: qualidade_dados_gold

Pergunta que responde

Quão confiáveis são os dados? Quantos chamados têm problemas de tempo, canal, motivo, resolução, custo, pesquisa, atendente ou cliente?

Fontes. fato, qualidade e dim_canal. Uma lista em Python define 27 regras; uma única passada conta todas com `COUNT_IF` e a função `stack` transforma as colunas em linhas.

Cada linha representa

Um indicador de qualidade (27 linhas), em formato longo: grupo, indicador, quantidade e % dos chamados.

- **Tempos (9):** não têm registro na base de horários; têm erro de leitura na abertura, no início ou no fim; tiveram o ano de abertura corrigido; tiveram virada de dia aplicada; foram atendidos mas ficaram sem espera válida ou sem duração válida após o tratamento; foram abandonados (informativo).
- **Canal (1):** têm canal não mapeado.
- **Motivo (1):** têm motivo não mapeado.
- **Resolução (2):** têm resolvido não informado; têm resolvido com valor inválido.
- **Custo (3):** não têm custo; têm custo inválido ou não positivo; têm mais de um custo.
- **Pesquisa (3):** não têm pesquisa; têm nota fora de 1 a 5; tiveram a nota recuperada pelo ajuste.
- **Atendente (7):** têm atendente ausente na origem (informativo); atendente inválido na origem; foram atendidos por humano sem atendente válido; têm atendente fora do cadastro; fora da vigência; autosserviço com atendente; nível do atendente que diverge do canal.
- **Cliente (1):** não têm id de cliente.

Atenção

- Os indicadores se sobrepõem: um chamado pode contar em vários. Não some as linhas.
- Os indicadores marcados como informativos (abandono, atendente ausente) descrevem o processo, não são necessariamente erro.
- É a base para responder à preocupação do Diretor de Tecnologia sobre inconsistências entre registros, custos e notas.

impacto_indicadores

Tabela gerada: impacto_indicadores_gold

Pergunta que responde

Quanto o tratamento dos dados muda cada indicador? Que conclusão o gestor tiraria se usasse os dados brutos?

Fontes. fato e qualidade. Sete consultas independentes unidas por UNION ALL; cada uma calcula o mesmo indicador por dois métodos.

Cada linha representa

Uma comparação entre dois métodos de calcular um indicador (7 linhas).

- **TME (min).** Método A: Bruto: todas as diferenças entre horários originais, inclusive negativas. Método B: Tratado: sequência válida, com correções
- **TME (min).** Método A: Só válidos, sem correção de ano e de dia. Método B: Tratado: sequência válida, com correções
- **TMA (min).** Método A: Bruto: todas as diferenças, inclusive negativas. Método B: Tratado: sequência válida, com correções
- **TMA (min).** Método A: Só válidos, sem correção de ano e de dia. Método B: Tratado: sequência válida, com correções
- **CSAT (%).** Método A: Nota válida (1 a 5). Método B: Nota ajustada (6 vira 5; 0 e -1 viram 1)
- **Custo médio por chamado (R$).** Método A: Só chamados com custo válido. Método B: Diluído em todos os chamados (sem custo conta como zero)
- **Taxa de resolução (%).** Método A: Sobre todos os chamados. Método B: Só chamados atendidos (exclui abandonados)
- **`indicador, metodo_a, metodo_b`**: O indicador e a descrição de cada método.
- **`valor_a, valor_b`**: Resultado de cada método.
- **`n_a, n_b`**: Quantos registros cada método usou.
- **`diferenca`**: valor_b menos valor_a.

É a tabela que justifica as decisões de limpeza no material executivo: mostra, em números, o quanto a escolha do tratamento altera o resultado.

simulacao_ganhos

Tabela gerada: simulacao_ganhos_gold

Pergunta que responde

Quanto o gasto com atendimento poderia cair com duas iniciativas: levar motivos simples para o autosserviço e reduzir os recontatos?

Fontes. fato, dim_motivo e dim_canal, mais as constantes `PCT_DEFLEXAO` e `PCT_REDUCAO_REINCIDENCIA`. Os blocos `meses`, `auto_global`, `a`, `b` e `calc` montam os cenários; a consulta final soma e anualiza.

Cada linha representa

Um motivo dentro de um cenário, mais uma linha " TOTAL " por cenário (aparece primeiro).

- **A) Deflexão de baixa criticidade para autosserviço.** Base de chamados: Chamados de motivos de criticidade baixa que hoje chegam ao Nível 1 ou 2. Ganho por chamado: Custo médio humano do motivo menos o custo médio no autosserviço (se o motivo não tem autosserviço, usa o custo médio global do autosserviço). Economia: Base × 20% × ganho
- **B) Redução de reincidência.** Base de chamados: Chamados reincidentes em 7 dias, de todos os motivos. Ganho por chamado: Custo médio dos chamados reincidentes do motivo. Economia: Base × 30% × ganho
- **`cenario, item`**: Cenário e motivo (ou " TOTAL ").
- **`chamados_base`**: Chamados sobre os quais a premissa age.
- **`premissa_pct`**: Percentual assumido (0,20 ou 0,30).
- **`chamados_evitados`**: Base × premissa.
- **`ganho_unitario`**: Economia por chamado evitado, em reais.
- **`economia_periodo`**: Economia no período inteiro.

- **`economia_mensal_media`**: Economia do período dividida pelos meses com dados.
- **`economia_anualizada`**: Média mensal vezes 12.

Atenção

- Os cenários se sobrepõem: um chamado reincidente de baixa criticidade pode estar nos dois. **Não some A e B.**
- Os percentuais de 20% e 30% são premissas. Mostre a sensibilidade (por exemplo 10%, 20% e 30%) ou a justificativa.
- A economia é de custo evitado por chamado. Não inclui o investimento para melhorar o autosserviço.
- A anualização é uma extrapolação linear da média mensal.

Fechamento

Conferência final de todas as tabelas geradas.

Resumo das tabelas Gold

O que faz. Percorre a lista das 23 tabelas Gold (9 do modelo e 14 analíticas) e imprime o número de linhas de cada uma. Se uma tabela não existir, imprime "não criada" em vez de falhar.

Cada linha representa

Uma linha de texto por tabela. Não é gravada nenhuma tabela.

Contagens de referência

- **`dim_calendario_gold`**: 731 (730 dias de 2025 e 2026 mais o desconhecido)
- **`dim_hora_gold`**: 25
- **`dim_faixa_espera_gold`**: 6
- **`dim_canal_gold`**: número de canais da Silver mais 1 (5, com os 4 canais atuais)
- **`dim_motivo_gold`**: número de motivos da Silver mais 1 (14 motivos na origem, então 15 se nenhum for descartado)
- **`dim_atendente_gold`**: número de atendentes mais 3
- **`fato_atendimento_gold e qualidade_chamado_gold`**: iguais ao total de chamados da Silver
- **`visao_geral_gold`**: 1
- **`kpi_mensal_gold`**: 19 (jan/2025 a jul/2026)
- **`comparativo_yoy_gold`**: 12
- **`funil_atendimento_gold`**: 4 canais (mais 1 se houver canal não mapeado)
- **`demanda_dia_hora_gold`**: no máximo 168
- **`qualidade_dados_gold`**: 27
- **`impacto_indicadores_gold`**: 7
- **`dim_cliente_gold`**: 47.705 (um por cliente da Silver; 47.706 se o membro SEM_CADASTRO vier a ser criado)
- **`perfil_cliente_gold`**: uma linha por faixa etária ou região em cada etapa do funil; o total depende do número de regiões e ainda não foi medido

Pontos de atenção do conjunto

- O notebook foi escrito a partir do código das Silvers, sem execução no Databricks. A primeira rodada pode revelar ajustes de nomes de colunas ou de tipos.
- `dim_cliente` e `perfil_cliente` são criadas hoje (`clientes_silver` já traz `id_cliente`), mas continuam condicionais a essa coluna. Idade, data de cadastro e dia de vencimento chegam como texto da Silver e são convertidos na Gold.

- 1.330 chamados (1,0%) têm `id_cliente` que não existe em `clientes_silver`. Sem o membro `SEM_CADASTRO` (proposta), ficam fora de `perfil_cliente`.
- O id do cliente entra na Gold como SHA-256 simples, sem segredo (decisão do grupo: o id do case é fictício).
- O nome do atendente aparece em `dim_atendente` e em `atendentes_desempenho`. Ele não é dado restrito; só falta decidir, para o material do Comitê Executivo, entre o nome real e "Atendente <id>".
- As premissas de 20% e de 30% da simulação são hipóteses e os cenários A e B se sobrepõem.
- O CSAT considera apenas quem respondeu. Confira a cobertura da pesquisa antes de comparar períodos.
- O funil é por canal; os dados não permitem acompanhar a jornada de um mesmo cliente entre etapas.
- A comparação ano a ano só é justa de janeiro a julho, os meses que existem nos dois anos.

Alterações desta versão (21/10/2026, revisão 2)

Esta versão corrige o guia com base na revisão contra os notebooks `Landing_To_Bronze`, `Bronze_To_Silver` e `Silver_To_Gold` e nas decisões do README.

- **dim_cliente e perfil_cliente.** Removido o aviso "hoje não é criada": `clientes_silver` já traz `id_cliente`. A condição continua no código (`DIM_CLIENTE_CRIADA`) e continua descrita.
- **Tipos.** Idade, data de cadastro e dia de vencimento vêm como texto da Silver e são convertidos na Gold, como no notebook.
- **Faixa etária.** Idade fora de 18 a 110 já vira nula na Silver e cai em "Sem idade"; retirada a nota sobre menores de 18 na faixa 18-24.
- **Hash do cliente.** SHA-256 simples, sem segredo (decisão do grupo: o id do case é fictício). A versão anterior deste guia citava HMAC; isso foi retirado.
- **Clientes sem cadastro.** 1.330 chamados (1,0%) com id sem correspondência na Silver. O notebook não cria membro desconhecido; `SEM_CADASTRO` segue como proposta.
- **Nome do atendente.** Não é dado restrito. A escolha entre nome real e rótulo anônimo vale só para o material do Comitê e continua em aberto.
- **status_atendente.** Mantido em `chamados_silver` (só a `base_silver` usa `status_id_atendente`); a Gold lê `chamados_silver`.
- **Contagens de referência.** Mantido "mais 1" em `dim_motivo_gold`; acrescentadas `dim_cliente_gold` e `perfil_cliente_gold`.